

基于图网络和体素的三维目标检测*

黄伟^{1,2} 金忠^{1,2}

(1. 南京理工大学计算机科学与工程学院 南京 210094)

(2. 南京理工大学高维信息智能感知与系统教育部重点实验室 南京 210094)

摘要 基于体素的三维目标检测模型在速度和检测精度上要超过基于图的模型,但是在体素化过程中使用平均池化操作会导致细节信息的丢失,从而在一定程度上降低模型的性能。论文使用图网络在体素化过程中显式构造拓扑结构捕获局部点云细节信息来解决体素化中的信息丢失问题,并通过裁剪体素骨干网络达到速度和检测精度的平衡。提出的方法在公开的三维目标检测数据库 KITTI 上进行了汽车类别目标的检测实验,取得了 84.85% 的均值精度 (AP) 检测结果,超过了一些先进的三维目标检测模型。

关键词 三维目标检测;图网络;体素化;特征处理

中图分类号 TN711 **DOI**: 10. 3969/j. issn. 1672-9722. 2025. 04. 011

3D Object Detection Based on Graph Network and Voxel

HUANG Wei^{1,2} JIN Zhong^{1,2}

(1. School of Computer Science and Engineering, Nanjing University of Science & Technology, Nanjing 210094)

(2. Key Laboratory of Intelligent Perception and Systems for High-Dimensional Information of Ministry of Education, Nanjing University of Science & Technology, Nanjing 210094)

Abstract The voxel-based 3D object detection model outperforms the graph-based model in terms of speed and detection accuracy, but the use of average pooling operation during voxelization leads to loss of detail information, which degrades the performance of the model to some extent. The proposed method uses a graph network to explicitly construct the topology to capture local point cloud detail information during voxelization to solve the information loss in voxelization, and achieves a balance of speed and detection accuracy by cropping the voxel backbone network. The proposed method is experimented on the KITTI, a publicly available 3D object detection database, for the detection of car class objects, and achieves 84.85% average precision (AP) detection results, which exceeds some advanced 3D object detection models.

Key Words 3D object detection, graph network, voxelization, feature processing

Class Number TN711

1 引言

随着自动驾驶技术的发展,开发准确高效的三维目标检测算法成为一个重要的研究方向。Qian 等^[1]提出与传统的可见光图像相比,点云数据可以提供更可信的深度信息,并有能力更准确地描述物体的空间形状。因此许多如车辆、行人目标检测^[2]等任务都使用三维点云作为输入。然而点云数据是无序的,在空间中分布不均匀,因此一些传统的图像处理^[3]不能直接应用于点云处理。目前

常用的两种点云数据处理方法分别是基于图网络的方法以及基于体素的方法。

基于图网络^[4]的方法直接应用点云数据进行学习,使用局部聚集机制,以迭代的方法学习关键点周围的局部结构特征^[5],从而使得模型可以感知点云数据中的密度、结构和关联等几何信息。但是数量庞大的点云数据带来沉重的计算压力,点云采样的随机数据访问增加了算法的延时,从而大大降低了模型的训练和推理速度。基于体素的方法将无序的点云数据转化为规则的体素数据,使用平均

* 收稿日期:2024 年 10 月 16 日,修回日期:2024 年 11 月 20 日

基金项目:国家自然科学基金项目(编号:61872188, 61972204)资助。

作者简介:黄伟,男,硕士研究生,研究方向:三维点云目标检测、深度学习。金忠,男,教授,博士生导师,研究方向:模式识别理论与应用、图像分析与机器智能、机器学习与数据挖掘。

池化计算体素网格点坐标和特征,从而利用卷积操作抽取点云数据的特征。同时体素网络使用稀疏卷积^[6]利用了体素本身的稀疏性,在速度上进一步超越了基于图网络的方法。但是体素化过程中使用体素特征代替体素内的点云特征导致了量化损失,在降低体素数据分辨率的同时限制了模型的检测能力上限。

本文在体素化之后增加一个特征处理图网络,通过显式构造拓扑结构将周围的点云细节信息编码到体素网格点上,使得输入到体素骨干网络中的体素特征富含局部细节信息,从而在一定程度上解决了量化损失问题,并通过剪裁体素骨干网络降低了网络整体的计算量,在KITTI数据集上的实验证明该方法能够有效提升整体模型的检测性能同时保持较高的检测速度。

2 相关工作

2.1 基于图网络的三维目标检测算法

Point-GNN^[4]使用最远点采样在输入的点云数据中选取一定数量的中心点,将固定半径内的临近点与中心点连接成边构造拓扑结构。网络在学习的过程中使用两点的坐标和特征生成边的特征,因而每个中心点都可以得到其所有邻接边的特征集合 S ,对特征 S 进行池化并使用多层感知机进行学习得到更新后的中心点特征。

Point-GNN^[4]使用这样的方法将点云的局部细节信息编码到中心点上,并且通过迭代扩大中心点的感知范围,从而得到富含细节信息和语义信息的中心点特征,并根据这些特征生成对应的三维目标包围框。

由此可见中心点的选取以及边的数量对基于图网络的算法影响很大^[7],尽管直接使用原始点云进行学习不会产生量化损失,但是学习过程中产生的数量庞大的边导致算法的运算速度缓慢,巨大的计算负担导致该算法的处理速度低下。

2.2 基于体素的三维目标检测算法

与基于图网络的模型相比,近年来基于体素的模型^[8]在三维目标检测领域取得了巨大的进步。Voxel-Net^[9]将点云空间划分为一个个相同大小的立方体,对立方体内的所有点云进行池化操作得到该立方体的特征,从而将无序的点云数据转化为有序的体素数据,减少了随机访问点云数据造成的时延,同时将传统的卷积操作应用于对体素数据的处理,降低点云数据的处理难度。

SECOND^[10]利用了体素数据的稀疏性提出了

稀疏卷积,通过跳过对空体素的处理减少了普通三维卷积中不必要的计算操作,在大大降低模型的计算量的同时得以堆积更多的网络层,从而可以抽取到更加高层的特征,具有更强的抽象能力,使其在检测速度和检测精度上都优于基于图网络的模型。

但是体素化过程中应用简单平均池化使用个体素代替体素内的所有点云的操作不可避免地导致了结构、密度以及关联等细节信息的丢失,从而产生了量化损失问题。如图1所示,大量的点云被少量的体素网格点取代,体素尺寸设置的越大体素化后产生的体素数量越少,这说明使用体素来表示代替点云表示并不是无损的,体素化会在一定程度上减弱输入数据对目标的描述能力。




图1 体素化后目标内体素和点云数量之比

3 本文提出的方法

3.1 特征处理图网络

本文将具有 n 个点的点云定义为集合 $P = \{p_1, p_2, \dots, p_n\}$,其中 $p_i = (x_i, s_i)$, $x_i \in R^3$ 表示该点的三维坐标, $s_i \in R^k$ 是一个长度为 k 的向量表示该点的属性特征,在原始点云数据中通常表示为该点的反射强度。




图2 特征预处理图网络构造边的方法

在给定点云 P 之后,本文按照式(1)、(2)、(3)计算尺寸大小为 $[w_v, h_v, l_v]$ 的体素网格的特征集合 V 。其中 $voxel_i$ 表示第 i 个体素, c_i 表示为体素网格点坐标, f_i 表示体素网格点的特征。如图2所示将体素网格点与固定半径 r 内的相邻点按照式(4)连接构成边集合 E ,从而得到图结构 $G=(P, V, E)$ 。

$$V = \{(c_1, f_1), (c_2, f_2), \dots, (c_m, f_m)\} \quad (1)$$

$$c_i = \text{Mean}(\{x_j | \forall p_j \in \text{voxel}_i\}) \quad (2)$$

$$f_i = \text{Mean}(\{s_j | \forall p_j \in \text{voxel}_i\}) \quad (3)$$

$$E = \{(c_i, x_j) | \|c_i - x_j\|_2 < r, \forall c_i \in V, \forall x_j \in P\} \quad (4)$$

本文遵从图网络常用的学习方法,按照式(5)为每个体素网格点构造所有邻接边的特征 β_i ,尽管图网络中存在多种构造边特征的方法,但是参考Liu^[11]等的研究结果,本文使用邻接点特征和坐标差进行拼接从而在保持较低计算复杂度的同时得到比较好的结果。

之后按照式(6)处理边特征集合,其中 R 表示将每个网格点的边进行随机采样到 T_k 条, S 表示用于特征学习的多层感知机, $\max$ 表示沿着通道的池化操作,将边特征聚集到对应的体素网格点上。最终将池化得到的特征与原先的体素网格点特征进行拼接得到更新后的体素网格点特征 f_i' 从而完成了特征预处理的操作。

$$\beta_i = \{(s_j, c_i - x_j) | \|c_i - x_j\|_2 < r, \forall x_j \in \text{voxel}_i\} \quad (5)$$

$$f_i' = (f_i, \max(S(R(\beta_i)))) \quad (6)$$

3.2 方法整体流程

本文通过将特征处理图网络插入到体素模型的体素化过程之后,将两种方法结合在一起。如图3所示,在每一次学习迭代中,特征处理图网络将原始点云数据和体素网格点信息作为输入,使用图网络将体素内和部分周围点云的信息进行编码更新体素网格点特征,取代了简单池化从而在一定程度上解决了量化损失问题。




图3 将特征预处理图网络插入到体素模型中的示意图

处理后的体素特征输入到体素神经网络中进行计算,产生预测的三维目标包围框并且计算损失用于反向传播,特征处理图网络的参数权重也会在反向传播中得到更新。

4 实验与分析

4.1 数据集

实验使用开放数据集 KITTI 来评估算法的性

能。KITTI数据集是一个在三维目标检测领域广泛使用的数据集,其中包含了7 481个训练样本以及7 518个测试样本。根据目标的遮挡情况以及目标内的点云数量,可以将目标的检测难度划分为简单、中等以及困难。

由于KITTI数据集只提供了在可视范围内的目标的真值标注,因此实验中首先将点云的范围剪辑成在 X 轴上为 $[0, 70.4]$ m, 在 Y 轴上为 $[-40, 40]$ m, 在 Z 轴上为 $[-3, 1]$ m。

本文在数据集中最常用的车辆类别目标上进行了实验,并且计算了不同难度下 IOU 阈值为 0.7 的均值准确率 (AP),使用该指标与基准模型和之前的工作进行对比。

4.2 实验设置

实验以 Voxel-RCNN^[12]模型作为基准模型,通过在体素化之后插入特征处理图网络评估方法的有效性。实验将特征预处理图网络的聚合半径大小 r 设置为 0.2 m,邻接点采样数量 T_k 设置为 9,输出的处理后体素网格点特征的张量维度为 20。为了让体素神经网络能够适应特征处理图网络的输出并减小模型整体的计算负担,实验中删除了 Voxel-RCNN 的骨干网络 VoxelBackBone8x 的前两个稀疏卷积组,并将第三个稀疏卷积组的输入维度大小调整为 20。

4.3 有效性分析

表1选取了近几年来较为优秀的基于体素的三维目标检测算法:SECOND^[10],Part-A²^[14]以及PV-RCNN^[15]。其中Baseline是前文提及的Voxel-RCNN^[12]算法,本文的改进是基于Baseline进行的。可以发现在KITTI数据集车辆类别目标三个难度的检测任务上本文的方法均超过了所有其他方法,相比较Baseline分别有0.22、0.29以及0.04的提升。尽管从数值上来看并不大,但是考虑到原本Baseline的性能已经相当不错,因此这些提升还是比较可观的,证明本文的改进方法是有效的。

表1 不同方法实验结果对比

方法	APcar		
	Easy	Mod.	Hard
SECOND ^[10]	87.43	76.48	69.10
Part-A ² ^[14]	87.81	78.49	73.51
PV-RCNN ^[15]	90.25	81.43	76.82
Baseline	89.41	84.52	78.93
本文方法	89.63	84.81	78.97
提升	0.22	0.29	0.04

4.4 特征处理图网络的复杂度分析

因为三维目标检测任务的特殊性,要求检测算法必须在具备高检测性能的同时具备较高的实时性,不能通过简单的堆叠网络层以降低推理速度的方法换取更高的检测性能。

因为特征处理图网络会使用多层感知机处理边特征以及池化操作后的体素特征,因此处理后的特征并不是低维向量而是高维向量。这意味着特征处理图网络也完成了一部分骨干网络的任务即进行特征抽取和提升维度。

如表 2 所示统计本文方法和 Baseline 的参数量以及运算速度,得到如表 2 所示结果。

表 2 复杂度分析对比

方法	参数量 /M	检测帧 率/fps	预处理 耗时/ms	骨干网络 耗时/ms
Baseline	7.59	39.92	1.2	10.2
本文方法	7.58	39.66	3.1	8.4

由表 2 可以看出,虽然特征处理图网络会增加一倍多的预处理耗时,但是由于其承担了部分特征抽取的任务,因此可以相应地删减骨干网络的部分网络层以达到平衡性能和速度的目的,预处理的耗时增加并不会明显降低方法的检测帧率。

5 结语

本文针对基于体素的三维目标检测方法在进行体素化时因为池化操作导致量化损失的问题展开分析,提出在将体素特征输入到体素骨干网络之前进行处理,利用图网络将局部点云信息编码到体素上,从而在一定程度上降低了体素化带来的量化损失,并且通过裁剪体素骨干网络降低整体算法复杂度,这对于部署具有实时性的高准确率体素检测模型具有实用价值,且在 KITTI 数据集上的实验结果表明该做法的优越性。

参考文献

[1] Qian R, Lai X, Li X. 3D object detection for autonomous driving: a survey[J]. Pattern Recognition, 2022: 108796.
[2] 陆怡悦,蔡云飞,石庭敏. 基于多线激光雷达与视觉信息的实时行人检测[J]. 计算机与数字工程, 2017, 45(11): 2256-2262.
LU Yiyue, CAI Yunfei, SHI Tingmin. Real-time Pedestrian Detection Based on Integration of Multi-line Radar and Visual Information[J]. Computer and Digital Engineering, 2017, 45(11): 2256-2262.
[3] Redmon J, Divvala S, Girshick R, et al. You only look

once: Unified, real-time object detection [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.
[4] Shi W, Rajkumar R. Point-GNN: Graph neural network for 3D object detection in a point cloud [C]// Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2020: 1708-1716.
[5] Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(1): 4-24.
[6] Graham B, Engelcke M, Van Der Maaten L. 3d semantic segmentation with submanifold sparse convolutional networks [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 9224-9232.
[7] 赵港,王千阁,姚烽,等. 大规模图神经网络系统综述 [J]. 软件学报, 2022, 33(01): 150-170.
ZHAO Gang, WANG Qiang, YAO Feng, et al. Survey on Large-scale Graph Neural Network Systems [J]. Journal of Software, 2022, 33(01): 150-170.
[8] Zheng W, Tang W, Chen S, et al. Cia-ssd: Confident iou-aware single-stage object detector from point cloud [C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(4): 3555-3562.
[9] Zhou Y, Tuzel O. Voxelnet: End-to-end learning for point cloud based 3d object detection [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4490-4499.
[10] Yan Y, Mao Y, Li B. Second: Sparsely embedded convolutional detection [J]. Sensors, 2018, 18(10): 3337.
[11] Liu Z, Hu H, Cao Y, et al. A closer look at local aggregation operators in point cloud analysis [C]//European Conference on Computer Vision. Springer, Cham, 2020: 326-342.
[12] Deng J, Shi S, Li P, et al. Voxel r-cnn: Towards high performance voxel-based 3d object detection [C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(2): 1201-1209.
[13] Yang Z, Sun Y, Liu S, et al. 3dssd: Point-based 3d single stage object detector [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11040-11048.
[14] Shi S, Wang Z, Shi J, et al. From points to parts: 3d object detection from point cloud with part-aware and part-aggregation network [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 43(8): 2647-2664.
[15] Shi S, Guo C, Jiang L, et al. Pv-rcnn: Point-voxel feature set abstraction for 3d object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 10529-10538.