

中图分类号: TP391 文献标识码: A 文章编号: 1006-8961(2022) 11-3331-12

论文引用格式: Liu W J, Wang J K and Qu H C. 2022. Multi-scale cost volumes information sharing based multi-view stereo reconstructed model. Journal of Image and Graphics, 27(11): 3331-3342 [刘万军, 王俊恺, 曲海成. 2022. 多尺度代价体信息共享的多视角立体重建网络. 中国图象图形学报, 27(11): 3331-3342] [DOI: 10. 11834/jig. 210774]

多尺度代价体信息共享的多视角立体重建网络

刘万军, 王俊恺*, 曲海成

辽宁工程技术大学软件学院, 葫芦岛 125105

摘要: 目的 多视角立体重建方法是3维视觉技术中的重要部分。相较于传统方法, 基于深度学习的方法大幅减少重建所需时间, 同时在重建完整性上也有所提升。然而, 现有方法的特征提取效果一般和代价体之间的关联性较差, 使得重建结果仍有可以提升的空间。针对以上问题, 本文提出了一种双U-Net特征提取的多尺度代价体信息共享的多视角立体重建网络模型。方法 为了获得输入图像更加完整和准确的特征信息, 设计了一个双U-Net特征提取模块, 同时按照3个不同尺度构成由粗到细的级联结构输出特征; 在代价体正则化阶段, 设计了一个多尺度代价体信息共享的预处理模块, 对小尺度代价体内的信息进行分离并传给下层代价体进行融合, 由粗到细地进行深度图估计, 使重建精度和完整度有大幅提升。结果 实验在DTU(Technical University of Denmark)数据集上与CasMVSNet相比, 在准确度误差、完整度误差和整体性误差3个主要指标上分别提升约16.2%, 6.5%和11.5%, 相较于其他基于深度学习的方法更是有大幅度提升, 并且在其他几个次要指标上也均有不同程度的提升。结论 提出的双U-Net提取多尺度代价体信息共享的多视角立体重建网络在特征提取和代价体正则化阶段均取得了效果, 在重建精度上相比于原模型和其他方法都有一定的提升, 验证了该方法的真实有效。

关键词: 3维重建; 深度学习; 多视角立体网络; 双U-Net网络; 特征提取; 代价体信息共享

Multi-scale cost volumes information sharing based multi-view stereo reconstructed model

Liu Wanjun, Wang Junkai*, Qu Haicheng

School of Software, Liaoning Technical University, Huludao 125105, China

Abstract: Objective Multi-view stereo (MVS) network is modeled to resilient a 3D model of a scene in the context of a set of images of a scene derived from photographic parameters-relevant multiple visual angles. This method can reconstruct small and large scales indoor and outdoor scenes both. The emerging virtual-reality-oriented 3D reconstruction technology has been developing nowadays. Traditional MVS methods mainly use manual designed similarity metrics and regularization methods to calculate the dense correspondence of scenes, which can be broadly classified into four categorized algorithms based on point cloud, voxel, variable polygon mesh, and depth map. These methods can achieve good results in ideal Lambert scenes without weakly textured areas, but it often fails to yield satisfactory reconstruction results in cases of texture scarcity, texture repetition, or lighting changes. Recent computer-vision-oriented deep learning techniques have promoted

收稿日期: 2021-09-02; 修回日期: 2021-10-29; 预印本日期: 2021-11-06

* 通信作者: 王俊恺 wangjunkailntu@163.com

基金项目: 国家自然科学基金项目(42071351); 辽宁省教育厅基础研究项目(LJ2019JL010); 辽宁工程技术大学学科创新团队资助项目(LNTU20TD-23)

Supported by: National Natural Science Foundation of China (42071351)

the newly reconstruction structure. The learning-based approach can learn the global semantic information. For example, there are based on the highlights and reflections of the prior for getting the more robust matching effect, so it was successively applied on the basis of the above traditional methods of deep learning. In general, MVS inherits the stereo geometry mechanism of stereo matching and improves the effect of the occlusion problem effectively, and it achieves greater improvement in accuracy and generalization as well. However, the existing methods have normal effects in feature extraction and poor correlation between cost volumes. We facilitate the multi-view stereo network with dual U-Net feature extraction sharing multi-scale cost volumes information. **Method** Our improvements are mainly focused on the feature extraction and cost volume regularization pre-processing. First, a dual U-Net module is designed for feature extraction. For all input images with a resolution of 512×640 pixels, after convolution and ReLU, the original image of 3 channels is conveyed to 8 channels and 32 channels, and the feature maps of 1, 1/4 and 1/16 of the original image size are generated by dual pooling-maximized and convolution-sustained, respectively. In the up-sampling stage, the multi-scale features information is sewed and channel dimension is fused for thicker features. The merged convolution and upsampling are continued to obtain a 32-channel feature map with the same resolution as the original image, and it is used as the input and passed through the U-Net network once more to finally obtain three sets of feature maps with different sizes. Such a dual U-Net feature extraction module can keep more detailed features through, downsampling (reduce the spatial dimension of the pooling layer), upsampling (repair the detail and spatial dimension of the object), and side-joining (repair the detail of the target). This can make the following depth estimation results more accurate and complete. Next, since the initially constructed cost volumes have no connection between different scales and rely on the upsampling of the feature extraction module only to maintain the connection, resulting in the information of the cost volumes in each layer cannot be transferred, we design a multi-scale cost volume information sharing module in the pre-regularization stage, which separates the cost volumes generated in each layer and fuse them into the next layer. To improve the estimation quality of the depth map, the small-scale cost volume information is fused into the cost volume of the next layer. **Result** The Technical University of Denmark (DTU) dataset used in this experiment is an indoor dataset specially shot and processed for MVS, which can directly obtain the internal and external photographic parameters of each view angle. It consists of 128 multiple objects or scenes based on 79 training scenes, 18 validation scenes and 22 test scenes. The training is equipped on Ubuntu 20.04 with an Intel Core i9-10920X CPU and an NVIDIA 3090 graphics card. There are three main evaluation metrics, which are the average distance from the reconstructed point cloud to the real point cloud, which can be called accuracy (*Acc*), the average distance from the real point cloud to the reconstructed point cloud, which can be called completeness (*Comp*) and the average value of accuracy and completeness, which can be called overall (*Overall*). Some secondary metrics are involved in, which are absolute value of depth error, absolute error and accuracy of 2 mm, absolute error and accuracy of 4 mm, etc. The experimental results show that our three main metrics like *Acc*, *Comp* and *Overall* are improved by about 16.2%, 6.5% and 11.5% compared to the original method. **Conclusion** Our reconstructed network model is developed via the multi-view stereo network with dual U-Net feature extraction sharing multi-scale cost volumes information method. It has a significant enhancement effect on both feature extraction and cost volume regularization, and the reconstructed accuracy has its feasible potentials.

Key words: 3D reconstruction; deep learning; multi-view stereo network; double U-Net network; feature extraction; cost volume information sharing

0 引言

随着虚拟现实、自动驾驶和现代医学等领域的应用需求增加,3 维视觉技术(龙霄潇等,2021)得以快速发展。本文主要研究的多视角立体(multi-view stereo,MVS)是一种通过已知相机参数的一组从不同视角拍摄的某个场景的图像恢复出图像内场

景的 3D 模型方法。这种方法既可以对小型物体进行重建,也可以对大规模的室外场景(颜深等,2021)进行重建。

传统的 MVS 方法通常可以分为 4 种类型,包括基于点云的算法、基于体素的算法、基于可变多边形网格的算法和基于深度图的算法。虽然这些方法在理想的朗伯场景下取得了很好的效果,但是在纹理匮乏、纹理重复或者光照变化的情况下经常无法得

到令人满意的重建结果。此外,这些方法通常需要很长时间建立对应的3维关系,对大型场景的重建更是大幅增加了时间的消耗。

随着深度学习技术在计算机视觉领域的迅速发展,学者对多视角立体重建结构的改善研究展现了极大的兴趣。在基于深度学习的立体匹配问题上,Luo等人(2016)以及Žbontar和LeCun(2016)将学习到的特征用于立体匹配和半全局匹配中进行后处理。GCNet(geometry and context network)(Kendall等,2017)引入3维代价体正则化进行立体估计并使用soft argmin操作回归最终的视差图。在MVS问题上,借鉴这些方法的思想,Ji等人(2017)提出一种基于体素的方法,将整个空间分解成更小的立方体,并以立方体为单位对曲面进行回归;Kar等人(2017)在网络中应用了可微投影,并提出了第1个用于MVS重建的端到端可学习网络;Huang等人(2018)将任意数量各种姿态的图像作为输入,首先产生一组平面扫描体,并使用DeepMVS网络来预测高质量的深度图。这些方法使用深度卷积神经网络,结合全局语义信息进行重建,在纹理较差的区域完成了较好的重建效果,在提升整体场景的重建质量的同时还大幅缩减了重建时间。

在Yao等人(2018)提出了一种端到端的MVS-Net之后,大多数的基于深度学习的MVS方法都是通过构建3D代价体,并用3D卷积神经网络对其进行正则化,最终回归深度图的方式进行。然而,由于3D卷积神经网络通常比较耗时且占用较大内存,便衍生出R-MVSNet(Yao等,2019)、Point-MVSNet(Chen等,2019)、Fast-MVSNet(Yu和Gao,2020)和CascadeMVSNet(Gu等,2020)等一系列网络模型。R-MVSNet采用在深度方向上使用循环神经网络的方法;Point-MVSNet采用直接基于点的匹配代价正则化的方法;Fast-MVSNet采用构造一个稀疏的代价体来学习稀疏的高分辨率深度图的方法;CascadeMVSNet则采用构建级联结构的3D代价体并由粗到细预测高分辨率深度图的方法。这些方法解决了耗时和占用内存较大的问题,实现高效率的重建。总体来说,MVS继承了立体匹配的立体几何理论基础,并借助更多的图像视角,有效地改善了遮挡问题的影响,在精度和泛化性方面都得到了较大的提升。但是,现有方法在特征提取的效果、匹配代价的正则化等方面依旧具有提升与改善的空间,在重建精度

方面也有待进一步提高。

针对以上问题,本文提出了一个双U-Net进行特征提取的多尺度代价体共享的多视角立体重建网络模型(multi-scale cost volumes MVSNet, MCV-MVSNet),该模型主要由特征提取、生成代价体、代价体正则化3个部分组成,本文主要工作总结如下:

1) 设计了一个改进的双U-Net特征提取模块,使提取到的特征更加精确,同时输出3个不同尺度的特征图,构成由粗到细的级联结构;

2) 设计了一个多尺度代价体信息共享模块,在对代价体进行正则化之前,将低尺度代价体信息逐层传递给高尺度的代价体,使后续预测的深度图更加准确。

1 相关工作

1.1 传统的MVS方法

在早期处理MVS的问题上,衍生出4种不同类型的算法。1) 基于点云的算法Furu(Furukawa和Ponce,2010)从一组稀疏的匹配特征点开始,将初始匹配向周围像素扩展,不断对特征点进行迭代处理,同时使用可见性约束来消除不正确的匹配,最终将其传播到低纹理区域实现稠密重建。由于这种方法对特征点的提取质量要求很高,在纹理分布不均匀的情况下很难取得较好的效果。2) 基于体素的算法(Sinha等,2007)先计算包含场景的边界框,然后将3D空间离散成不规则网格,找出在场景表面附近的体素。这种方法的内存消耗会随着体素分辨率的增加而增加,同时,体素分辨率也限制了重建的精度。3) 基于可变多边形网格的算法(Furukawa和Ponce,2009;Li等,2016)需要对场景表面进行初始猜测,对表面演化进行初始化,然后进行迭代操作,提高多视图光度一致性并对场景表面进行演化。4) 基于深度图的算法Camp(Campbell等,2008)、Tola(Tola等,2012)、Gipuma(Galliani等,2015)和Colmap(Schönberger等,2016)等都是将整个重建过程分解成若干个单视图深度图估计过程,再将所有的深度图融合在一个坐标系下的点云中。这种方法可以轻易地将深度图融合到点云或体积重建中,是进行3维重建的最优方法。

1.2 基于深度学习的MVS方法

深度学习技术在近年来表现得愈发成熟,基于

深度学习的 MVS 方法也在逐渐展现其巨大的潜力。Ji 等人(2017)通过将相机参数与图像以 3D 体素共同编码表示的方式构建出了一个 3D 全卷积网络 SurfaceNet。它将整个空间分割成更小的彩色立方体,然后使用通用的 3D 卷积神经网络对小立方体进行正则化并回归到场景表面。虽然这种方法解决了多视立体视觉问题,提高了空间分辨率,但是也导致时间复杂度大大提升。Kar 等人(2017)提出了第 1 个用于低分辨率 MVS 重建的端到端可学习网络,通过可微分投影的方式将图像的特征构建成特征体,并对每个体素是否被场景表面占据进行分类,最后对每个视角的投影进行解码输出深度图。然而这种方法受到内存的限制,只能对小规模场景进行低分辨率重建。Huang 等人(2018)将输入图像进行预处理,并将其投影到生成的一组 3D 平面扫描体中,通过 DeepMVS 网络对 3D 平面扫描体进行处理,最终生成细化的深度图。整个 DeepMVS 网络主要分为 3 个部分,分别是补丁匹配网络、平面扫描体内特征聚合以及平面扫描体间相互特征聚合,最后将估计出的高质量深度图输出。

Yao 等人(2018)提出了一种端到端的 MVSNet,参照传统平面扫描法的策略,采用可微单应性变换来实现多视角图像特征的映射,用以构建参考图像的匹配代价。同时,为了使得匹配代价不受图像数量的影响,MVSNet 采用了基于方差的匹配代价构建方式,通过一个沙漏型的 3 维卷积层与回归操作最终实现了对参考图像的深度估计,并成功超越了传统算法的性能。但是,受到深度采样数的影响,MVSNet 对计算资源的占用较高。为了解决这一问题,Yao 等人(2019)提出了一种基于递归神经网络的可扩展多视角立体重建框架 R-MVSNet,此方法通过门控循环单元(gated recurrent unit,GRU)在不同深度处对特征图串行地进行正则化处理,避免了一次性对整个 3D 代价体进行正则化。虽然这种方法大大减少了对内存的占用,但是却会显著增加运行时间。Point-MVSNet(Chen 等,2019)提出了直接利用点云表示来对目标场景进行处理,这种方法采用了由粗到细的深度估计策略,通过迭代的方式不断提升深度估计的精度,在深度图的基础上直接生成 3 维点云。此方法在构建每个 3 维点的匹配代价之后,通过 K 邻近搜索为 3 维点聚合空间邻域信息,并基于多层感知机对每个 3 维点单独进行匹配代价

正则化,自然地保持了表面结构的连续性。因此实现了比基于空间代价矩阵的方法精度更高、计算效率更优的图像深度估计。Fast-MVSNet(Yu 和 Gao, 2020)构造了一个稀疏的代价体,利用小尺度卷积神经网络对局部区域内像素的深度依赖性进行编码,以加密稀疏的高分辨率深度图,最后提出了一种简单而有效的高斯-牛顿层来进一步优化深度图。这种由稀疏到密集的策略保证了方法的效率,能够快速完成端到端的学习过程。CascadeMVSNet(Gu 等,2020)将 MVSNet 的模型改成了层级的,先通过预测下采样四分之一的深度图,然后缩减当前尺度的深度假设范围,继续预测下采样二分之一的深度图,最终预测出原始图像大小的深度图。这种层级的方式,可以采用大的深度间隔和小的深度区间,从而可以一次训练更多数据。此方法中自适应的深度采样确保了内存资源用在更有意义的区域上,可以显著减少计算时间和内存消耗。

综上所述,现有的 MVS 方法仍然受到内存大小的限制,硬件上 GPU 内存的加大也为实现更高精度的重建结果提供了可能。因此,在特征提取阶段,可以增加卷积层数,以得到效果更好的特征图;在代价体的级联结构中也可以传递更多的有效信息,使深度图的估计更加准确。

2 本文算法

目前基于深度学习的多视角立体匹配方法的特征提取的效果一般和代价体之间的关联性较差,因此本文在 Gu 等人(2020)方法的基础上,在特征提取阶段和代价体正则化前期处理阶段进行了改进。整体网络框架如图 1 所示,与 MVSNet 类似,将输入的 N 幅图像分成两组,其中一组只有一幅图像,将其命名为参考图像;另外一组为其余的 $N-1$ 幅图像,称为源图像。首先将图像进行特征提取,借助 U-Net 结构,同时分别输出原图像大小 $1/4$ 、 $1/2$ 和 1 倍大小的特征图,构成“由粗到细”的级联结构。然后对特征图进行可微单应性扭曲操作,将源图像的特征图扭曲到参考图像中,构建成多个特征体,再对特征体进行方差的差异度量操作,将多个特征体构建成一个代价体。再将第 m ($1 \leq m \leq 2$) 层生成的代价体分离,其中一个代价体进行正则化,回归并预测深度图,另一个代价体与第 $m+1$ 层生




图1 多尺度代价体信息共享的多视角立体重建网络模型框架图

Fig. 1 The framework of multi-view stereo network with multi-scale cost volumes information sharing

成的代价体融合成新的代价体,再继续后续操作,直到预测出与原图像尺度大小相同的深度图。按照特征提取、代价体的构建、代价体正则化和损失函数 4 个部分详细说明 MCV-MVSNet 的完整流程。

2.1 特征提取

特征提取是整个多视角立体匹配重建最重要的部分,重建效果取决于特征提取的效果。Yao 等人

(2018,2019) 通过卷积神经网络进行特征提取,而 Chen 等人(2019) 和 Gu 等人(2020) 利用改进U-Net (Ronneberger 等,2015) 构建特征金字塔进行特征提取,且效果优于前者,因此,本文设计了一个改进双U-Net 特征提取模块,如图2所示,该模块通过两次U-Net 网络的处理,进一步对纹理信息丰富的高频区域增加局部感受野,以获得更优的特征信息。




图2 双 U-Net 特征提取模块结构图

Fig. 2 Double U-Net feature extraction module structure diagram

U-Net 网络模型起初用于医学影像处理中,它采用对称结构构成“U”的形状,前端为特征编码器,通过不断地卷积和池化提取图像的深层特征,但同时得到的特征图大小相较于原来的图像也在不断减小,网络越深,丢失的信息越多。因此,在后端的特征解码器中,对于每一次下采样,都采用一次上采样使之恢复原来的尺寸,而每一个上采样的结果都与前期相应尺寸的特征图进行叠加融合,这样便实现

了高层特征与低层特征的结合,增加特征图像的细节信息,能更精确地预测每一个像素的类别。

本文在双 U-Net 特征提取模块中,对所有的分辨率为 512×640 像素的输入图像,经过卷积和 ReLU 后,将 3 通道的原始图像变为 8 通道再变为 32 通道,通过两次最大池化以及不断卷积,分别生成原图像尺寸的 $1/4$ 和 $1/16$ 倍的特征图。在上采样阶段,将不同尺度的特征信息在通道维度上进

行拼接融合,形成更厚的特征,在侧边合并后继续卷积和上采样,得到 32 通道的与原图像分辨率相同的特征图,再将此作为输入,再经过一次 U-Net 网络,最终得到 3 组不同尺寸的特征图,按照特征图由大到小的顺序对应的通道数分别为 8、16 和 32。这样的双 U-Net 特征提取模块可以保留更加丰富的细节特征,下采样减少池化层的空间维度,上采样修复物体的细节和空间维度,而侧边连接能更好地修复目标的细节,使后续的深度估计结果更加准确完整。

2.2 代价体的构建

代价体的构建使用平面扫描的方法,其原理是对于每个深度,将源图像投影到参考相机平截头体的前向平行平面上,然后再投影到参考图像上来匹配参考图像。大多数的 MVS 方法均采用平面扫描法来构建代价体,本文也沿用 Yao 等人(2018)方法。首先对特征图进行可微单应性扭曲变换将其聚合成多个特征体。在深度假设 d 处,使用 d 将源图像的所有像素投影到空间中,然后通过参考相机反向扭曲这些点,因此,第 i 个视角的源图像与参考图像在深度 d 上的单应性 $H_i(d)$ 可以表示为

$$H_i(d) = K_i \cdot R_i \cdot \left(I - \frac{(t_0 - t_i) \cdot n_0^T}{d} \right) \cdot R_0^T \cdot K_0^T \quad (1)$$

式中, K_i , R_i 和 t_i 分别代表第 i 个视角源图像相机的内参、旋转和平移, K_0 , R_0 和 t_0 分别代表参考图像相机的内参、旋转和平移, n_0 代表参考相机的主轴, I 表示假设平面间隔。通过单应性的变换,再将聚合到的特征体 F_i 进行基于方差的差异度量操作以构建成代价体 C , 这种操作方式能够适应任意数量 N 的输入特征体,可以表示为

$$C = \frac{\sum_{i=1}^N (F_i - \bar{F})^2}{N} \quad (2)$$

式中, $\bar{F}$ 表示特征体的平均值。

2.3 代价体正则化

由于初步构建的代价体可能会因为存在非朗伯表面或物体遮挡而造成噪声污染,因此应该结合平滑度约束推断深度图,即代价体正则化操作,将生成的代价体经过一个类似 3D U-Net 的正则化网络生成进行深度图推断的概率体。Yang 等人(2019)在立体匹配问题上提出了一种分层的特征体解码器,输入的特征体经过 3 维卷积和金字塔池化将其分为输出特征体和输出代价体,这样做的目的是利用构建的代价体金字塔中的潜在关系,提高其精度。因此,本文在代价体正则化操作之前对生成的代价体进行预处理,模块结构如图 3 所示。




图3 多尺度代价体信息共享模块结构图

Fig. 3 Multi-scale cost volumes information sharing module structure diagram

由于 3 个尺度生成的代价体之间几乎没有任何联系,仅仅依靠特征提取模块的上采样保持仅有的关联,导致每层中代价体的信息无法传递。因此,本文在代价体正则化的预处理阶段设计了一个多尺度代价体信息共享模块,其作用是将每层生成的代价体进行分离并且将其融合到下一层中,使小尺度的

代价体信息融合进下一层的代价体中,以提高深度图的估计质量。以顶层为例,生成的代价体 C_1 的 5 维尺度为 $1 \times 32 \times 48 \times 128 \times 160$, 首先将其通过 3 次 3 维卷积块,随后将其进行金字塔池化以获取足够的上下文信息,随后的分离操作是对其分别进行上采样和 3 维卷积。经过上采样得到的 $1 \times 16 \times$

$32 \times 256 \times 320$ 的代价体 C_{1N} 与中间层生成的代价体 C_2 具有同样大小的尺度,因此将其融合,形成第 2 层新的 $1 \times 32 \times 32 \times 256 \times 320$ 代价体 C_{2F} ,与此同时,经过 3 维卷积后的 $1 \times 1 \times 48 \times 128 \times 160$ 的代价体 C_{1T} 进入到 3D U-Net 模块中进行代价体正则化。以此类推,在第 3 层融合生成的代价体 C_{3F} ,便可以将其送入 3D U-Net 模块中并估计最终的深度图。

2.4 损失函数

在 3 层级联模型中,对每一层的损失都进行监督,总损失定义为

$$Loss_{total} = \lambda_1 L_1 + \lambda_2 L_2 + \lambda_3 L_3 \quad (3)$$

式中, λ_1 , λ_2 , λ_3 为 3 个阶段的损失权重,在级联结构中,一般分辨率越高,设置的权重越大,因此本文也采用与 CasMVSNet(Gu 等,2020) 相同的设置,即为 0.5、1 和 2, L_1 , L_2 , L_3 分别为小、中、大 3 个不同尺度的损失。对于 L_m , 本文将其定义为 SmoothL1 Loss,具体如下

$$L_m = Loss(x, y) = \frac{1}{n} \sum_m z_m \quad (4)$$

$$z_m = \begin{cases} 0.5(x_m - y_m)^2 & |x_m - y_m| < 1 \\ |x_m - y_m| - 0.5 & \text{其他} \end{cases} \quad (5)$$

式中, n 为图像个数, m 为级联结构中的层数, x_m 和 y_m 分别为估计深度和真实深度。

3 实验及结果分析

3.1 数据集及实验设置

本文采用 DTU (Technical University of Denmark) 数据集(Aanaes 等,2016) 进行实验。DTU 数据集是针对 MVS 而专门拍摄并处理的室内数据集,利用一个搭载可调节亮度灯的工业机器人臂对一个物体进行多视角的拍摄,每个物体所拍的视角都经过严格控制,可以直接获取每个视角的相机内、外参数。它由 128 个不同的物体或场景组成,其中有 79 个训练场景、18 个验证场景和 22 个测试场景,每个训练的物体或场景共拍摄 49 个视角,每个视角共有 7 种不同的亮度,共有 27 097 个训练样本,每幅影像的分辨率为 $1\,600 \times 1\,200$ 像素。同时,每个场景还提供了真值点云以供计算。

使用 DTU 训练集进行训练时,初始的输入图像

分辨率为 512×640 像素,输入图像个数 $N=3$ 。3 层的深度假设的个数分别为 48、32 和 8,对应的深度间隔分别为 MVSNet(Yao 等,2018) 间隔的 4、2 和 1 倍。3 个尺度的特征图分辨率分别为原始图像分辨率大小的 $1/16$ 、 $1/4$ 和 1 倍。在训练中,使用 Adam 优化器并设置参数 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ 。训练的初始学习率设置为 0.001,总共进行 16 轮训练,在第 10、12 和 14 轮后将学习率进行减半处理。本文方法在 1 块英伟达 3090 显卡上进行训练,批量大小设置为 1,具体环境配置如表 1 所示。

表 1 本文的环境配置

Table 1 Environment configuration for this paper

类别	型号或版本
操作系统	Ubuntu 20.04
CPU	Intel Core i9-10920X
GPU	GeForce RTX 3090(24 GB)
内存	64 GB
Python 版本	3.7.0
CUDA 版本	11.0
Pytorch 版本	1.7.1

3.2 评价指标

在 DTU 数据集提供的 MATLAB 代码上可以进行准确性和完整性的实验评估,输入生成的点云文件,与真值点云进行计算可得。评价指标主要有 3 个,分别是准确度误差 *Acc*、完整度误差 *Comp* 和整体性误差 *Overall*。其中, *Acc* 计算的是重建点云到真实点云之间的平均距离,代表了 MVS 重建得到的点云整体质量; *Comp* 计算的是真实点云到重建点云之间的平均距离,代表了 MVS 重建得到的点云捕获的点在重建曲面上的多少; *Overall* 计算的是准确度误差 *Acc* 和完整度误差 *Comp* 的均值。同时,给定阈值的误差绝对值和准确率也可以反映出网络更加全面的性能,例如深度误差绝对值、2 mm 误差绝对值及准确率,4 mm 误差绝对值及准确率等。

3.3 对比实验

为了验证本文模型的有效性,以 3 个主要指标 *Acc*、*Comp* 和 *Overall*(数值越小为越优) 与前人模型的结果进行对比,详细信息如表 2 所示。

表2 MCV-MVSNet 与其他方法主要评估指标对比

Table 2 Comparison of the main evaluation metrics of MCV-MVSNet and other methods

方法	文献	/mm		
		<i>Acc</i>	<i>Comp</i>	<i>Overall</i>
Camp	Campbell 等人(2008)	0.835	0.554	0.695
Furu	Furukawa 和 Ponce(2010)	0.613	0.941	0.777
Tola	Tola 等人(2012)	0.342	1.190	0.766
Gipuma	Galliani 等人(2015)	0.283	0.873	0.578
SurfaceNet	Ji 等人(2017)	0.450	1.040	0.745
MVSNet	Yao 等人(2018)	0.396	0.527	0.462
R-MVSNet	Yao 等人(2019)	0.383	0.452	0.417
Point-MVSNet	Chen 等人(2019)	0.342	0.411	0.376
Fast-MVSNet	Yu 和 Gao(2020)	0.336	0.403	0.370
CascadeMVSNet	Gu 等人(2020)	0.421	0.382	0.401
MCV-MVSNet	本文	0.353	0.357	0.355

注: 加粗字体表示各列最优结果。

由表2可以看出,本文方法在 *Comp* 和 *Overall* 两个指标上均优于对比方法,在 *Acc* 指标上也排名靠前,证明了本文方法在定量结果上的真实有效。同时,与 CascadeMVSNet (Gu 等,2020) 在绝对误差和准确率上的对比如表3所示,在深度误差绝对值

上提升约 7.3%,在 2 mm 误差绝对值和准确率上均有提升,虽然在 4 mm 误差绝对值的表现不如原方法,但是在 4 mm 准确率上也还是有所提升,也可以证明本文方法在改进后比原方法的效果更加明显。

表3 MCV-MVSNet 与原方法次要评估指标对比

Table 3 Comparison of the secondary evaluation metrics of MCV-MVSNet and the original method

方法	深度误差绝对值	2 mm 误差绝对值	4 mm 误差绝对值	2 mm 准确率/%	4 mm 准确率/%
CascadeMVSNet	9.152	0.733	2.725	75.05	84.50
MCV-MVSNet	8.481	0.575	2.772	79.06	86.50

本文选取了 scan4 和 scan48 两个场景重建后的效果与真值点云、MVSNet (Yao 等,2018) 和 CascadeMVSNet (Gu 等,2020) 进行对比,如图4所示,本文方法相较于 MVSNet 方法,消除了很多噪声的影响,更加专注于对物体本身的重建,而相较于 CascadeMVSNet 方法,在红框内的细节表现更好,重建的完整性效果也得以证实。

3.4 消融实验

针对本文提出了两个改进,分别对其进行单独的测试,测试结果如表4所示。第1行为原始 CascadeMVSNet (Gu 等,2020) 得到的结果,第2行、第3行分别为在原始模型基础上添加双 U-Net 特征提取模块和多尺度代价体信息共享模块后得到的结果,第4行为整体改进后的模型得到的结果。可以看

出,两个模块相对于原始模型均有提升,证明了两个模块均具有有效性。

同时,如图5所示,对每个实验估计的深度图进行对比,同样选取 scan4 和 scan48 两个场景的最终深度估计图,可见在添加每一个模块后均比原始方法更加完整。相较于原方法以及单独添加某个模块的方法,本文方法对周边噪声的消除起到了更好的效果,重建物体边缘的平滑度也有所提升,使得根据深度图估计出的3维模型也有一定的提升。

本文主要针对重建的精度指标进行改进,以内存消耗和运行时间为代价获取更高的精度。使用双 U-Net 特征提取模块旨在提取到更加精准、完整的特征图,此模块对提取到的特征进行反复处理,增加了大量的计算,同时,需要缓存大量的中间数据。同

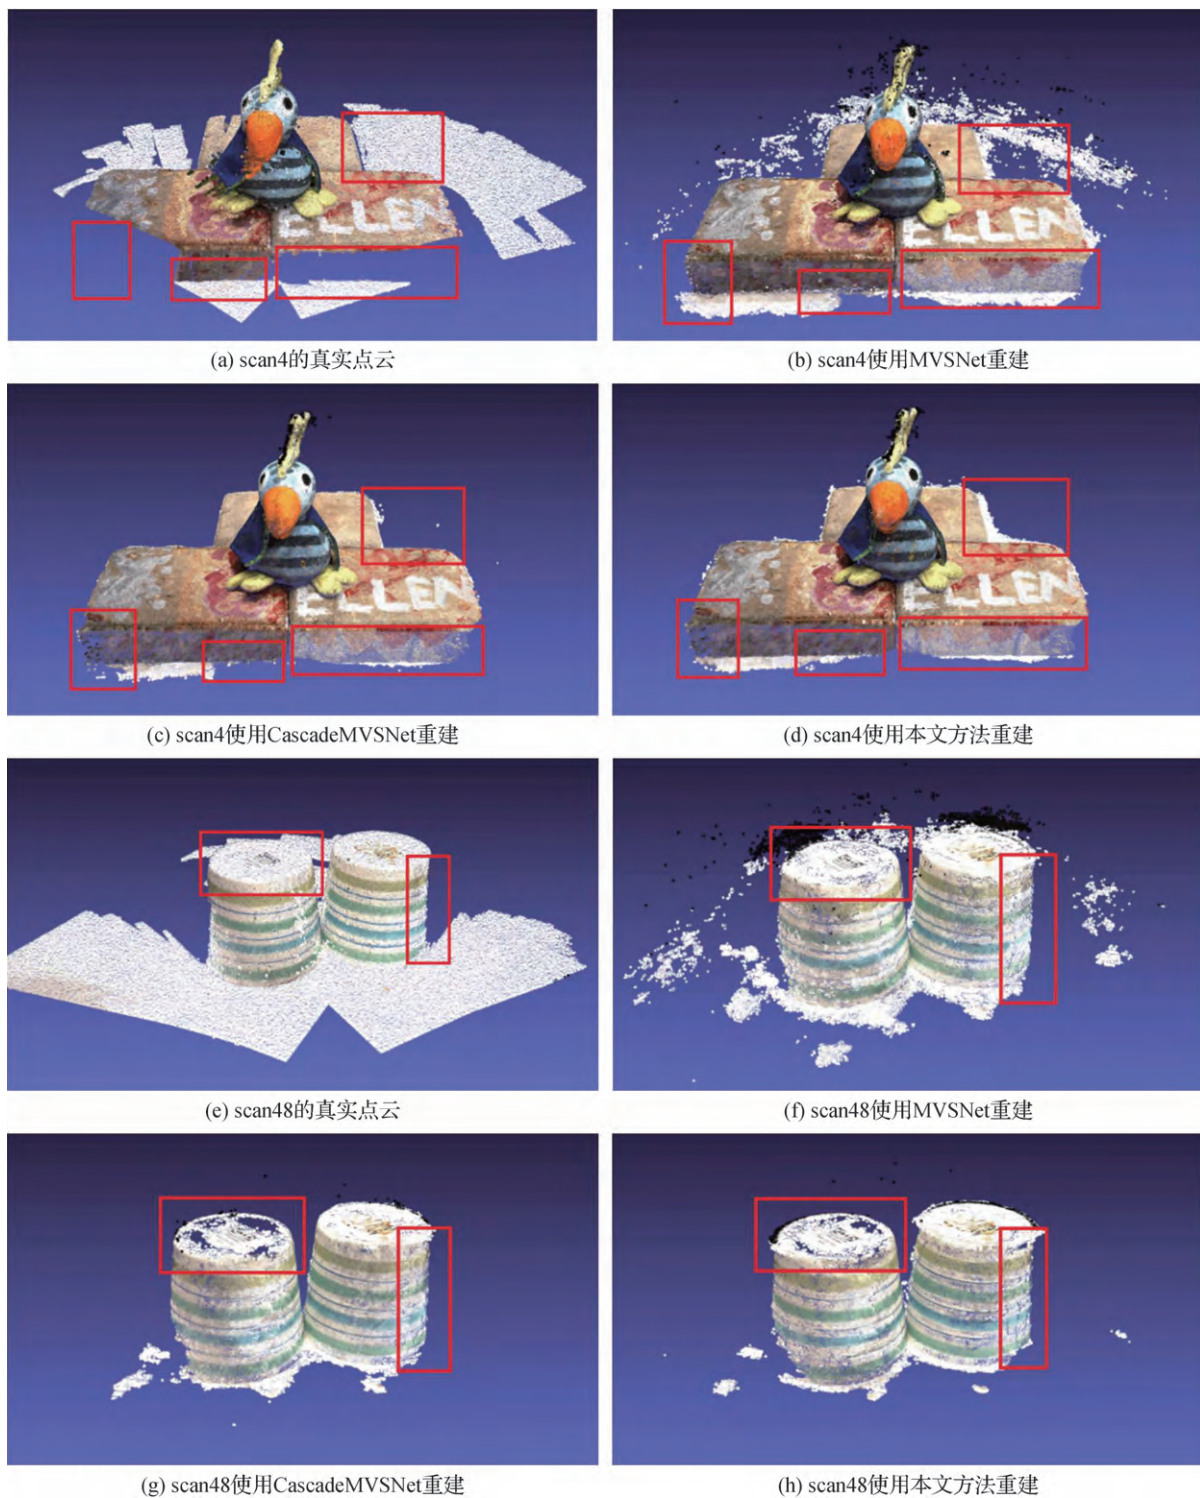


图 4 scan4 和 scan48 使用不同方法重建的结果对比

Fig. 4 Comparison of the reconstruction results of scan4 and scan48 using different methods

((a) ground truth of scan4; (b) scan4 using MVSNet; (c) scan4 using CascadeMVSNet;

(d) scan4 using ours; (e) ground truth of scan48; (f) scan48 using MVSNet;

(g) scan48 using CascadeMVSNet; (h) scan48 using ours)

表 4 消融实验评估指标对比
Table 4 Comparison of evaluation metrics for ablation experiments

方法	Acc/ mm	Comp/ mm	Overall/ mm	深度误差 绝对值	2 mm 误差 绝对值	4 mm 误差 绝对值	2 mm 准确率/%	4 mm 准确率/%
CascadeMVSNet	0.421	0.382	0.401	9.152	0.733	2.725	75.05	84.50
CasMVSNet + U-Net 特征提取模块	0.397	0.349	0.373	8.661	0.676	2.737	77.30	85.12
CasMVSNet + 双 U-Net 特征提取模块	0.380	0.359	0.370	8.524	0.557	2.760	78.35	85.46
CasMVSNet + 多尺度代价体共享模块	0.405	0.378	0.392	8.943	0.659	2.731	76.32	84.80
MCV-MVSNet	0.353	0.357	0.355	8.481	0.575	2.772	79.06	86.50

注: 加粗字体表示各列最优结果。




图 5 scan4 和 scan48 在分别添加不同模块后估计的最终深度图

Fig. 5 The final estimated depth maps of scan4 and scan48 after adding different modules respectively
((a) original images; (b) ground truth depth maps; (c) CasMVSNet; (d) adding U-Net feature extraction module;
(e) adding double U-Net feature extraction module; (f) adding multi-scale cost volumes information sharing module; (g) ours)

理,在代价体正则化的预处理阶段,多尺度代价体信息共享模块也需要缓存大量的小尺度代价体计算结果,用于与大尺度代价体进行融合。因此,本文实验在每添加一个模块后,其对应的内存消耗和运行时间均有所提高,具体数据如表 5 所示,而这也是后续

工作的主要目标,即如何在维持精度不变的同时,有效降低内存消耗和运行时间。

4 结 论

针对基于深度学习的多视角立体重建方法中出现的特征提取的效果一般和代价体之间的关联性较差的问题,本文提出了一种新的多视角立体网络模型 MCV-MVSNet,对特征提取和代价体正则化阶段分别进行了改进。为了提高特征的完整性和准确性,设计了一个双 U-Net 网络结构进行特征提取;为了增加不同层代价体之间的相互关联,使代价体内的信息可以逐层传递,设计了一个多尺度代价体信息共享模块,以提高深度图的估计质量。本文方法在 DTU 数据集上相比于其他基于深度学习的方法,在重建精度上取得了优异的效果,相比于传统方法更是大幅缩减了运行时间。但是,随着重建精度的

表 5 消融实验内存消耗和占用时间对比
Table 5 Comparison of memory consumption and occupied time for ablation experiments

方法	内存 消耗/GB	占用时 间(s/次)
MVSNet	7.1	0.4
CascadeMVSNet	6.2	0.8
CasMVSNet + U-Net 特征提取模块	9.7	1.0
CasMVSNet + 双 U-Net 特征提取模块	13.2	1.4
CasMVSNet + 多尺度代价体共享模块	14.8	2.6
MCV-MVSNet	21.4	3.1

提升,相较于其他基于深度学习的方法,本文方法由于卷积规模增大,代价体之间的计算也会加大,导致 GPU 的占用内存提高,同时训练时间也在增加。在后续工作中,将进一步调整网络结构,以减少内存消耗,缩短运行时间。

参考文献(References)

- Aanaes H, Jensen R R, Vogiatzis G, Tola E and Dahl A B. 2016. Large-scale data for multiple-view stereopsis. *International Journal of Computer Vision*, 120(2): 153-168 [DOI: 10.1007/s11263-016-0902-9]
- Campbell N D F, Vogiatzis G, Hernández C and Cipolla R. 2008. Using multiple hypotheses to improve depth-maps for multi-view stereo// *Proceedings of the 10th European Conference on Computer Vision*. Marseille, France: Springer: 766-779 [DOI: 10.1007/978-3-540-88682-2_58]
- Chen R, Han S F, Xu J and Su H. 2019. Point-based multi-view stereo network//*Proceedings of 2019 IEEE/CVF International Conference on Computer Vision*. Seoul, Korea (South): IEEE: 1538-1547 [DOI: 10.1109/ICCV.2019.00162]
- Furukawa Y and Ponce J. 2009. Carved visual hulls for image-based modeling. *International Journal of Computer Vision*, 81(1): 53-67 [DOI: 10.1007/s11263-008-0134-8]
- Furukawa Y and Ponce J. 2010. Accurate, dense, and robust multiview stereopsis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32(8): 1362-1376 [DOI: 10.1109/TPAMI.2009.161]
- Galliani S, Lasinger K and Schindler K. 2015. Massively parallel multi-view stereopsis by surface normal diffusion//*Proceedings of 2015 IEEE International Conference on Computer Vision*. Santiago, Chile: IEEE: 873-881 [DOI: 10.1109/ICCV.2015.106]
- Gu X D, Fan, Z W, Zhu S Y, Dai Z Z, Tan F T and Tan P. 2020. Cascade cost volume for high-resolution multi-view stereo and stereo matching//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Seattle, USA: IEEE: 2492-2501 [DOI: 10.1109/CVPR42600.2020.00257]
- Huang P H, Matzen K, Kopf J, Ahuja N and Huang J B. 2018. DeepMVS: learning multi-view stereopsis//*Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Salt Lake City, USA: IEEE: 2821-2830 [DOI: 10.1109/CVPR.2018.00298]
- Ji M Q, Gall J, Zheng H T, Liu Y B and Fang L. 2017. SurfaceNet: an end-to-end 3D neural network for multiview stereopsis//*Proceedings of 2017 IEEE International Conference on Computer Vision*. Venice, Italy: IEEE: 2326-2334 [DOI: 10.1109/ICCV.2017.253]
- Kar A, Häne C and Malik J. 2017. Learning a multi-view stereo machine [EB/OL]. [2021-08-17]. <https://arxiv.org/pdf/1708.05375.pdf>
- Kendall A, Martirosyan H, Dasgupta S, Henry P, Kennedy R, Bachrach A and Bry A. 2017. End-to-end learning of geometry and context for deep stereo regression//*Proceedings of 2017 IEEE International Conference on Computer Vision*. Venice, Italy: IEEE: 66-75 [DOI: 10.1109/ICCV.2017.17]
- Li Z X, Wang K Q, Zuo W M, Meng D Y and Zhang L. 2016. Detail-preserving and content-aware variational multi-view stereo reconstruction. *IEEE Transactions on Image Processing*, 25(2): 864-877 [DOI: 10.1109/TIP.2015.2507400]
- Long X X, Cheng X J, Zhu H, Zhang P J, Liu H M, Li J, Zheng L T, Hu Q Y, Liu H, Cao X, Yang R G, Wu Y H, Zhang G F, Liu Y B, Xu K, Guo Y L and Chen B Q. 2021. Recent progress in 3D vision. *Journal of Image and Graphics*, 26(6): 1389-1428 (龙霄潇, 程新景, 朱昊, 张朋举, 刘浩敏, 李俊, 郑林涛, 胡庆拥, 刘浩, 曹汛, 杨睿刚, 吴毅红, 章国锋, 刘焯斌, 徐凯, 郭裕兰, 陈宝权. 2021. 三维视觉前沿进展. *中国图象图形学报*, 26(6): 1389-1428 [DOI: 10.11834/jig.210043]
- Luo W J, Schwing A G and Urtasun R. 2016. Efficient deep learning for stereo matching//*Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition*. Las Vegas, USA: IEEE: 5695-5703 [DOI: 10.1109/CVPR.2016.614]
- Ronneberger O, Fischer P and Brox T. 2015. U-Net: convolutional networks for biomedical image segmentation//*Proceedings of the 18th International Conference on Medical Image Computing and Computer-Assisted Intervention*. Munich, Germany: Springer: 234-241 [DOI: 10.1007/978-3-319-24574-4_28]
- Schönberger J L, Zheng E L, Frahm J M and Pollefeys M. 2016. Pixel-wise view selection for unstructured multi-view stereo//*Proceedings of the 14th European Conference on Computer Vision*. Amsterdam, the Netherlands: Springer: 501-518 [DOI: 10.1007/978-3-319-46487-9_31]
- Sinha S N, Mordohai P and Pollefeys M. 2007. Multi-view stereo via graph cuts on the dual of an adaptive tetrahedral mesh//*Proceedings of the 11th IEEE International Conference on Computer Vision*. Rio de Janeiro, Brazil: IEEE: 1-8 [DOI: 10.1109/ICCV.2007.4408997]
- Tola E, Strecha C and Fua P. 2012. Efficient large-scale multi-view stereo for ultra high-resolution image sets. *Machine Vision and Applications*, 23(5): 903-920 [DOI: 10.1007/s00138-011-0346-8]
- Yan S, Zhang M J, Fan Y C, Tan X H, Liu Y, Peng Y and Liu Y X. 2021. Progress in the large-scale outdoor image 3D reconstruction. *Journal of Image and Graphics*, 26(6): 1429-1449 (颜深, 张茂军, 樊亚春, 谭小慧, 刘煜, 彭杨, 刘宇翔. 2021. 大规模室外图像 3 维重建技术研究进展. *中国图象图形学报*, 26(6): 1429-1449 [DOI: 10.11834/jig.200842]
- Yang G S, Manela J, Hapold M and Ramanan D. 2019. Hierarchical deep stereo matching on high-resolution images//*Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition*

- tion. Long Beach, USA: IEEE: 5510-5519 [DOI: 10.1109/CVPR.2019.00566]
- Yao Y, Luo Z X, Li S W, Fang T and Quan L. 2018. MVSNet: depth inference for unstructured multi-view stereo//Proceedings of the 15th European Conference on Computer Vision. Munich, Germany: Springer: 785-801 [DOI: 10.1007/978-3-030-01237-3_47]
- Yao Y, Luo Z X, Li S W, Shen T W, Fang T and Quan L. 2019. Recurrent MVSNet for high-resolution multi-view stereo depth inference//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE: 5520-5529 [DOI: 10.1109/CVPR.2019.00567]
- Yu Z H and Gao S H. 2020. Fast-MVSNet: sparse-to-dense multi-view stereo with learned propagation and gauss-newton refinement//Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE: 1946-1955 [DOI: 10.1109/cvpr42600.2020.00202]
- Žbontar J and LeCun Y. 2016. Stereo matching by training a convolutional neural network to compare image patches. Journal of Machine Learning Research, 17(1): 2287-2318

作者简介

刘万军,男,教授,主要研究方向为软件工程理论、图像与视觉信息计算、模式识别与人工智能。

E-mail: liuwanjun@lntu.edu.cn

王俊恺,通信作者,男,硕士研究生,主要研究方向为图像与视觉信息计算、3 维重建。

E-mail: wangjunkailntu@163.com

曲海成,男,副教授,主要研究方向为遥感影像高性能计算、目标检测与识别。

E-mail: quhaicheng@lntu.edu.cn