

第3次作业:

(1) 真正例 TP: 正确地识别正常人

假正例 FP: 错误地将患者识别为正常人

真反例 TN: 正确地将识别患者

假反例 FN: 错误地将正常人识别为患者

$$\text{查准率 } P_1 = \frac{78}{78+4} = 0.9512 \quad \text{查全率 } R_1 = \frac{78}{78+2} = 0.975$$

$$F_1 = 2 \times \frac{0.9512 \times 0.975}{0.9512 + 0.975} \approx 0.963$$

$$(2) \text{系统2: 查准率 } P_2 = \frac{80}{88} = 0.9091 \quad \text{查全率 } R_2 = \frac{80}{80} = 1$$

$$F_2 = 2 \times \frac{0.9091 \times 1}{0.9091 + 1} \approx 0.9524$$

(3) 系统1的查准率高于系统2, 查全率略低于系统2, 但 F_1 值高于系统2. 由此综合来看, 系统1更优.

T2 (1) 当阈值为0.7时

Score > 0.7 时样本预测为正常

	实际正	实际负
预测正	2	4
预测负	1	3

ROC曲线点坐标计算: $TPR = \frac{TP}{TP+FN} = \frac{2}{2+4} = 0.333$

$$FPR = \frac{FP}{FP+TN} = \frac{1}{4+3} = 0.25 \quad (0.25, 0.333)$$



(2) 混淆矩阵:

	实际正	实际负
预测正	4	1
预测负	2	3

ROC曲线计算

$$TPR = \frac{TP}{TP+FN} = \frac{4}{4+2} = 0.6667$$


$$FPR = \frac{FP}{FP+TN} = \frac{1}{1+3} = \frac{1}{4} = 0.25$$

坐标 (0.25, 0.6667)

T3. $y = \frac{1}{1 + e^{-(w^T x + b)}}$

(2) $y = \frac{1}{1 + e^{-(w^T x + b)}}$ 用来计算输入数据 x 属于正例的概率 y 理解为
输入数据 x 为正例的概率 y 理解为 x 为负例的概率
即 $P(y=1|x)$.

$\frac{P}{1-P}$ 为几率. 反映 x 作为正例的可能性.



输出范围有界为 (0, 1), 连续可导, 单调性, 平滑性



74

1) 使用 ID3 算法搭建决策树
利用信息熵进行处理

$$g = -\sum p_i \log_2 p_i$$

$$\text{数据集 } H(D) = -\frac{9}{15} \log_2 \frac{9}{15} - \frac{6}{15} \log_2 \frac{6}{15} = 0.971$$

$$\text{年龄: 信息增益 } g(D, A_1) = H(D) - \left[\frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \right] \\ = 0.083$$

有无工作的信息增益:

$$g(D, A_2) = H(D) - \left[\frac{5}{15} H(D_1) + \frac{10}{15} H(D_2) \right] \\ = 0.324$$

$$\text{有无房子: } g(D, A_3) = H(D) - \left[\frac{6}{15} H(D_1) + \frac{9}{15} H(D_2) \right] \\ = 0.971 - 0.551 = 0.420$$

$$\text{信贷情况的信: } g(D, A_4) = 0.971 - 0.608 = 0.363$$


选择子节点 同理

$$\text{年龄: } g(D, A_1) = 0.251$$

$$\text{有工作 } g(D, A_2) = 0.918$$

$$\text{信贷情况 } g(D, A_4) = 0.474$$

由此可得决策树为



(2) CART 算法

$$Gini = 1 - \sum_{i=1}^n p_i^2$$

$$Gini(D) = 1 - \left(\frac{9}{15}\right)^2 - \left(\frac{6}{15}\right)^2 = 0.48$$

计算每个特征的基尼指数

$$Gini(D, A_1) = \frac{5}{15} \left(2 \times \frac{2}{5}\right)^2 + \frac{10}{15} \left(2 \times \frac{7}{10}\right)^2 = 0.44$$

$$Gini(D, A_1=2) = 0.48$$

$$Gini(D, A_1=3) = 0.44$$

$A_1=1$ 或 $A_1=3$ 可作为最优划分

同理: $Gini(D, A_2=1) = 0.32$


$$Gini(D, A_3=1) = 0.27$$

$$Gini(D, A_4=2) = 0.36$$

$$Gini(D, A_4=2) = 0.47$$

$Gini(D, A_3=1) = 0.27$ 最小, 可作为最优划分

最终划分 有自己的层次



15.

(1) $\min_{w, b} \frac{1}{2} \|w\|^2$

s.t. $y_i (w \cdot x_i + b) - 1 \geq 0 \quad i=1, 2, \dots, N$

求得最优的 w^*, b^*

由此可得 $\min \frac{1}{2} (w_1^2 + w_2^2)$

s.t. $4w_1 + 3w_2 + b \geq 1$

$-2w_1 + 3w_2 + b \geq 1$

$-w_1 - w_2 - b \geq 1$

求得此最优化的问题的解

$w_1 = 0.8, w_2 = -0.4, b = -1.4$

(2)

于是最大间隔分离超平面

$0.8x^{(1)} - 0.4x^{(2)} - 1.4 = 0$

其中 $w_1 = (0.8)^T$ 与 $x_3 = (1, 1)^T$ 为支持向量

可以化为 $4x^{(1)} - 2x^{(2)} - 7 = 0$

分类函数 $f(x) = \text{sign}(0.8x^{(1)} - 0.4x^{(2)} - 1.4)$

