


第 6 章

数据链路层与局域网

中国科学技术大学
自动化系 郑烱
改编自 Jim kurose, Keith Ross



*Computer Networking: A
Top-Down Approach*

8th edition

Jim Kurose, Keith Ross

Pearson, 2020


数据链路层与局域网：目标

- 理解链路层服务背后的原理：
 - 检错，纠错
 - 广播型信道的共享：多路访问
 - 链路层编址
 - 局域网：以太网，VLAN
- 各种链路层技术的实例和实现



链路层：导论

- 网络层解决了一个网络如何到达另外一个网络的路由问题
- 还需要解决：在一个网络内部如何由一个节点到达子网中另外一个相邻节点
- 从IP的角度：一跳问题
 - 子网内：主机到主机
 - 主机到路由器
 - 路由器到路由器
- 链路层提供这个IP子网内相邻两点的传输服务
 - 从IP层的角度来看是一跳(hop)
 - 链路层的角度来看可能是多个物理跳




链路层：导论

■ 网络互联回顾

- IP over everything
- 从IP的角度来看是IP网络
- 但是从之下来看是各种物理网络

■ 路由器连接两个IP网络

- 路由器插入多个网卡分别接入到不同的物理网络A和B中
- 网络层进行路由匹配和转发



■ 路由器转发分组

- 从A物理网络网卡收到分组，在IP层面转发表匹配和转发，到B物理网络的网卡
- 通过B物理网络的链路层发送给同一个IP网络的其他IP节点

■ IP网络内的一跳可能包含着多个链路层转发

链路层和局域网：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

链路层：简介

术语：

- 节点：主机和路由器
- 链路：沿着通信路径将邻近的节点连在一起的通信信道
 - 有线，无线，局域网
- 第2层的协议数据单位： 帧
 - 用于封装IP数据报

链路层 负责将IP数据报通过链路从一个节点传送到**物理上相邻的**另外一个节点



链路层：上下文

- 同一个IP数据报在不同链路上使用不同链路层协议传输
 - 例如：第一段链路WiFi，下一段链路为以太网
- 每种链路层协议提供的服务是不同的
 - 例如：在有些链路层提供可靠数据传输，有些不提供

交通的类比：

- 普林斯顿到洛桑的旅行
 - 轿车：普林斯顿到JFK
 - 飞机：JFK到日内瓦
 - 火车：日内瓦到洛桑
- 旅行者 = 数据报
- 每个交通段=通信链路
- 交通模式=链路层协议
- 交通代理=路由算法


链路层：服务

■ 成帧，链路接入：

- 封装IP数据报到帧中，加上帧头和帧尾
- 如果共享型介质，发送之前需要信道接入
- 在头部加入“MAC”地址标识帧的源以及目标（和IP地址不一样）


■ 在相邻节点之间进行可靠传输

- 我们已经学过如何进行可靠数据传输
- 在低出错率链路上很少使用
- 无线链路：出错率高
 - Q: 为什么链路层可靠性和端到端可靠性都要有？




链路层：服务（续）

- **流量控制：**
 - 在相邻的发送和接收节点控制帧的间隔，从而控制发送速率
- **差错检验：**
 - 错误通常由信号间的干扰和噪声引起
 - 接收方检测差错，发送方重传或者丢弃错误的帧
- **差错纠正：**
 - 无需重传，接收方就可以标识和纠正比特错误
- **半双工和全双工通信：**
 - 在半双工情况下，链路两端的节点都可以发送，但是不能够同时进行




在哪里实现链路层?

- 在每台主机和路由器的网卡上
- 链路层（和相应的物理层）实现于网络接口卡（*NIC: network interface card*）或者芯片上
 - 以太网网卡，WiFi网卡或者芯片
 - 实现了链路层和物理层功能
- 网卡连接到了主机的系统总线，通过驱动和主机（或者路由器）的OS相连
- 硬件、软件和固件的组合



接口间的通信



发送方:

- 封装数据报到帧中
- 增加差错检测位，执行可靠数据传输和流量控制机制等功能

接收方:

- 检查有无出错，执行可靠数据传输和流量控制等功能
- 解封装数据报，在接收主机将之交给上层

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

差错检测

EDC: 差错检测和纠正位 (即: 冗余位)

D: 被差错检测保护的数据, 可能包括PDU头部字段的内容




差错检测不是100% 可靠 !

- 协议可能遗漏一些错误, 但是非常少 (残存错误)
- EDC越大, 检测和纠正效果越好

奇偶校验

单比特校验:


- 检测单个位的错误



偶校验: 设置校验位使得1的位数为偶数

2维比特校验:

- 可以检测和纠正单个位的错误



no errors:

1	0	1	0	1	1
1	1	1	1	0	0
0	1	1	1	0	1
1	0	1	0	1	0

detected and correctable single-bit error:

1	0	1	0	1	1
1	0	1	1	0	0
0	1	1	1	0	1
1	0	1	0	1	0

parity error

* Check out the online interactive exercises for more examples: http://gaia.cs.umass.edu/kurose_ross/interactive/

互联网校验和 (复习)

目标: 在传输的段中检查错误（例如：反转的位）

发送方:


- 将UDP段的内容当成16比特的整数序列（包括UDP头部和IP地址）
- **校验和:** 校验范围的内容和（和的反码）
- 校验和的值放入UDP校验和字段

接收方:

- 计算接收段的校验和
- 检查计算出的校验和是否等于校验和字段的值:
 - 不相等-出错了
 - 相等-没有错误被检查出来，但是可能存在错误？后续...

循环冗余校验码 (CRC:Cyclic Redundancy Check)

- 更加强大的差错检测码
- **D**: 数据位 (给定的, 降至视为二进的数)
- **G**: 一个 $r+1$ 位的比特模式 (生成器) (给定的)



目标: 选择 r 位 CRC 位 **R**, 让 $\langle D, R \rangle$ 能够被 **G** (模 2 运算) 整除

- 接收器知道 **G**, 将 $\langle D, R \rangle$ 除以 **G**, 如果余数为非零: 检测到错误!
- 可以检测到小于 $r+1$ 位的所有突发错误
- 在实践中广泛使用 (以太网、802.11 WiFi)

Cyclic Redundancy Check (CRC): 例子

我们希望:

$$D \cdot 2^r \text{ XOR } R = nG$$


或者等价的:

$$D \cdot 2^r = nG \text{ XOR } R$$

或者等价的: :

如果我们希望 $D \cdot 2^r$ 可以整除 G ,
则余数 R 应该满足:

$$R = \text{remainder} \left[\frac{D \cdot 2^r}{G} \right]$$



* Check out the online interactive exercises for more examples: http://gaia.cs.umass.edu/kurose_ross/interactive/

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

多路访问链路、协议

2种类型的“链路”将网络层相邻2个节点连接起来：

■ 点到点

- 连接远端2台路由器的点到点链路
- 以太网交换机和主机的点到点链路
- 用于拨号接入的PPP

■ 广播式 (共享线缆或者媒体)

- 老式总线型以太网（同轴电缆连接各主机）
- 有线（cable）接入网络中的上行HFC
- 802.11 WLAN，4G/5G，卫星网络




共享型线缆 (如：有线以太网)



共享无线电: 4G/5G



共享无线电: WiFi



共享无线电: 卫星



鸡尾酒会上的人们
(共享空气和声场)

多路访问协议

- 单个的共享型广播信道
- 2个或者多个节点的同时发送：干扰
 - **碰撞**：如果节点同时接收到了2个或者多个信号

多路访问协议

- 决定节点如何共享信道的分布式算法，即确定节点什么时间可以发送
- 有关于信道共享的通信必须借助信道本身！
 - 没有用于协调的带外信道

理想的多路访问协议

给定: 速率为 R bps的多路访问信道(MAC)

理想特性:

1. 当一个节点发送时, 它可以按照信道速率 R 进行全速传输
2. 当 M 个节点发送时, 每个节点按照 R/M 平均速率发送
3. 完全分布式:
 - 没有用于协调传输的特殊节点
 - 无需在时钟上和时隙上进行同步
4. 简单

MAC协议：分类

3大类型：

■ 信道划分

- 将信道划分为更小的“分片”（时隙、频段、编码和光的波段）
- 将“分片”分配给节点用于其独享

■ 随机访问

- 信道不再划分为分片，允许碰撞
- 要有从碰撞中恢复的机制


■ 轮次

- 节点轮流使用，但是拥有很多数据传输的节点可能会得到更多的轮转使用时间

信道划分MAC协议：TDMA

TDMA: time division multiple access 时分多路复用


- “轮流”访问信道
- 每个站点在每一轮中获得固定长度的时隙（长度=包发送时间）
- 没有使用的时隙会空闲，此时信道的资源会被浪费
- 例子：6个站点的LAN，1，3，4时隙有数据发送，2，5，6时隙空闲



信道划分MAC协议: FDMA

FDMA: frequency division multiple access 频分多路复用

- 信道频谱被分为频带
- 每个站点被分配给一个固定的频带
- 在某个频带上未被使用的频带空闲，会被浪费
- 例子：6个站点的LAN，1, 3, 4有包发送，频带2, 5, 6空闲



随机访问协议

- 当一个节点有数据包要发送时：
 - 按照全信道速率 R 发送
 - 节点间没有预先的协调
- 2个或多个正在传输的节点会发生“碰撞”
- 随机访问协议要规范：
 - 如何检测碰撞
 - 如何从碰撞中恢复（例如：通过延后的重传）
- 随机访问MAC协议的例子：
 - ALOHA, slotted ALOHA
 - CSMA, CSMA/CD, CSMA/CA

时隙 ALOHA

假设:


- 所有的帧大小一样
- 时间被分成相等大小的时隙（传输一个帧所用的时间）
- 节点仅仅在时隙的开始进行传输
- 节点需要在时间上同步
- 如果2个或者多个节点在一个时隙上传输，所有节点都会检测出碰撞

运行:

- 当节点获得了一个新帧，在下一个时隙进行传输
 - 如果没有碰撞：该帧发送成功，节点可在下一个时隙发送新帧
 - 如果发生碰撞：节点将会在下一个时隙以概率 p 发送，直到成功

随机化 - 为什么?

时隙 ALOHA



优点:

- 单个活动节点可以以信道全速率进行连续发送
- 高度分布式: 仅仅需要节点在时隙上取得时间上的同步
- 简单

缺点:

- 有碰撞, 存在浪费时隙的现象
- 即使有帧要发送, 也有空闲的时隙
- 节点可以在小于一个帧传输时间内检测到碰撞, 但还必须要发完该帧
- 节点需要时钟上的进行同步


时隙 ALOHA: 效率

效率: 长期来看, 成功时隙所占的比例 (假设有很多节点, 每个节点都有很多帧要发送)

- 假设: N 个具有很多帧要发送的节点, 每个节点在时隙中传输的概率为 p
 - 给定节点在一个时隙中成功发送的概率 = $p(1-p)^{N-1}$
 - 任何一个节点成功发送的概率 = 信道成功传输帧的概率 = $Np(1-p)^{N-1}$
 - 最大利用率: 发现能够让 $Np(1-p)^{N-1}$ 最大化的 p
 - 对于很多节点而言, 当 N 趋于无穷时, 求 $Np^*(1-p^*)^{N-1}$ 的极限, 得到:
 - 最大效率 = $1/e = .37$
- 最好情况: 信道有37%的时间被用于有效的帧传输!

纯 ALOHA

- 不分隙 Aloha: 简单, 无需同步
 - 一旦帧到达: 立即传输
- 由于没有同步, 碰撞的概率增加:
 - 在 t_0 时开始传输的帧 (黄色) 会和其他的在 $[t_0-1, t_0+1]$ 开始传输的帧碰撞



- 纯Aloha的最大效率: 18.5% !

CSMA (carrier sense multiple access)


简单 **CSMA**: 为了进一步提高信道利用率, 在传输之前侦听:

- 如果信道空闲: 传送整个帧
- 如果信道忙碌: 推迟发送
- 人类的类比: 不要打断别人正在进行的说话!

CSMA: 碰撞

- 即使有CS载波侦听，仍然会发生碰撞
 - 传播延迟意味着2个节点可能听不到另外一个节点刚开始的传输
- 碰撞时：如果坚持将一个帧发送给完毕，该帧的整个传输时间会被浪费掉
 - 距离和传播延迟在决定碰撞概率时扮演一个重要的角色
 - 距离越远，冲突的可能性越大


原因：节点依据本地的信道使用情况来判断全局信道的使用情况



CSMA/CD:

CSMA/CD: CSMA with *collision detection*

- 碰撞将会在一小段时间内就被检测到
 - 碰撞的传输会被立即中止，可以进一步降低对信道的浪费
 - 在有线网络中碰撞很容易被检测到，但是在无线网络中很难检测到碰撞（WLAN 不适用CSMA/CD，而是CSMA/CA）
- 人类类比：有礼貌的说话者，我在说的時候别人如果说话，我就停止



Ethernet CSMA/CD 算法

1. NIC从网络层接收到数据报，创建帧
2. NIC 检测信道:
 - 如果空闲: 开始帧的传输
 - 如果忙碌: 侦听信道直到空闲，然后开始传输，一边传输一边CD
3. 如 NIC在传输一整个帧时都没发生碰撞，NIC完成了该帧的传输！
(无需等确认，以太网在链路层不提供可靠传输)
4. 如果 NIC 在发送时检测到其他的传输: 放弃，发送jam干扰信号，强化冲突
5. 在放弃之后，NIC 进入二进制（指数）退避：
 - 在第m次碰撞后，NIC在 $\{0, 1, 2, \dots, 2^m - 1\}$ 中随机选择一个值K，NIC等待 $K \cdot 512$ 位时后，返回第2步尝试重传
 - 更多的碰撞: 退避时间间隔更长（在发生碰撞的可能性和节点平均发送时间之间取得权衡，适应信道载荷的变化）

以太网CSMA/CD算法（续）

二进制指数退避：

- 目标：适配器试图适应当前负载，在一个适应性的变化碰撞窗口中随机选择时间点尝试重发
 - 高负载：重传窗口时间大，冲突可能性减少，但等待时间长
 - 低负载：使得各站点等待时间少，但冲突可能性增大

- 首次碰撞：在 $\{0, 1\}$ 选择 K ；延迟 $K*512$ 位时尝试重发
- 第2次碰撞：在 $\{0, 1, 2, 3\}$ 选择 K ，延迟 $K*512$ 位时尝试重发
-
- 第10次碰撞：在 $\{0, 1, 2, 3, \dots, 1023\}$ 选择 K ，延迟 $K*512$ 位时尝试重发


CSMA/CD 效率

- T_{prop} = LAN中2个站点最大传输延迟
- t_{trans} = 最大尺寸帧的传输时间

$$efficiency = \frac{1}{1 + 5t_{prop}/t_{trans}}$$

- 效率=1
 - 当 t_{prop} 趋近于0时：一旦一个帧发送，CS机制立即让所有节点检测到，不会发送冲突
 - 当 t_{trans} 趋近于无限大时：一旦一个节点占据信道，会一直发送
- 比ALOHA的性能要好：而且简单，便宜，分布式！

Manchester 编码



- 在 10BaseT中使用
- 每一个bit的位时中间有一个信号跳变
- 允许在接收方和发送方节点之间进行时钟同步
 - 节点间不需要集中的和全局的时钟
- 10Mbps，使用20M带宽，效率50%
- Hey, this is physical-layer stuff!

100BaseT中的4b5b编码

- 0000->11110
- 0001->01001
- 0010->10100
- 0011->10101
- 0100->01010
- 0101->01011
- 0110->01110
- 0111->01111
- 1000->10010
- 1001->10011
- 1010->10110
- 1011->10111
- 1100->11010
- 1101->11011
- 1110->11100
- 1111->11101

千兆以太网

- 采用标准的以太帧格式
- 允许点对点链路和共享广播信道
- 交换模式：全双工千兆可用于点对点链路
 - 站点使用专用信道，基本不会冲突，效率高
 - 除非发往同一个目标站点
- 在共享模式，继续使用CSMA/CD MAC技术，节点间需要较短距离以提高利用率
- 物理编码：8b10b编码
- 10 Gbps now !

“轮次” MAC协议

信道划分MAC协议:

- 在高负载时，高效、公平性地共享信道
- 在低负载时效率不高：信道访问的延迟，即使只有一个站点活跃它也只能获得 $1/N$ 带宽！

随机访问 MAC 协议

- 低负载时比较有效：单个忙碌的节点可以充分利用信道！
- 高负载是：反复碰撞，信道的浪费很严重


“轮次” 协议

- 具备以上二者的优点！

“轮次” MAC协议

轮询:


- 主节点依次“邀请”其它节点进行传输
- 经常与“哑”设备一起使用
- 关注点:
 - 轮询代价
 - 延迟
 - 单点故障点 (主节点)




“轮次” MAC协议

令牌传递:

- 控制令牌依次从一个节点传到下一个节点
- 令牌报文
- 关注点:
 - 令牌代价
 - 延迟
 - 单点故障（令牌）




有线接入网络: FDM, TDM 和随机访问的综合运用!



- ❖ 从**头端**到各终端的下行(广播)信道通过**FDM**分为**多个**40Mbps信道
 - 传输互联网信息、数字电视和分配给终端上行信道的控制信息等
 - **互联网信道**: 只有1个CMTS在其上传输, 专享
- ❖ **多个**30 Mbps上行的信道, FDM
 - **多路访问**: 所有终端用户使用; 接着TDM分成微时隙
 - **部分时隙**: 分配用于各种端传输数据; **部分时隙**: 用于竞争式进行信道预约


有线接入网络:



DOCSIS: data over cable service interface specification

- ❖ 采用FDM进行信道的划分：若干上行、下行信道
- ❖ 下行信道：
 - ❖ 时隙分配结果：在下行MAP帧中，CMTS告诉各节点微时隙分配方案，分配给各站点的上行微时隙
 - ❖ 互联网下行数据：CMTS头端传输下行数据（给各用户）

有线接入网络:



DOCSIS: TDM上行信道

- ❖ 采用TDM的方式将上行信道分成若干微时隙: MAP规定
- ❖ 站点采用分配给它的微时隙上行数据传输: CMTS分配的
- 在特殊的上行微时隙中, 各站点请求上行微时隙: 竞争
 - 各站点对于该时隙的使用是随机访问的
 - 一旦碰撞 (请求不成功, 结果是: 在下行的MAP中没有为它分配, 则二进制退避) 选择时隙上传输

MAC协议总结

- 信道划分，通过划分时间，划分频率或者编码
 - TDMA, FDMA, CDMA
- 随机访问 (动态),
 - ALOHA, S-ALOHA, CSMA, CSMA/CD
 - 载波侦听: 在有些网络中容易（有线），而在有些很难（无线）
 - CSMA/CD 在以太网中被使用
 - CSMA/CA 在 802.11 WLAN中被使用
- 轮次
 - 通过中心节点的轮询，令牌传递
 - 蓝牙, FDDI, 令牌环

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程


MAC 地址

- 32-bit IP 地址:
 - 接口的网络层地址，被用于三层（网络层）的转发
 - IP地址分层，便于进行全互联网的路由计算
 - e.g.: 128.119.40.136
- MAC (or LAN or physical or Ethernet) 地址:
 - 功能:
 - 在一个IP子网范围内区分一个网卡（主机、路由器）和其他一些网卡，地址平面的
 - 从而从一个LAN接口将帧传递到物理上（一个子网范围内）相连另外一个接口
 - 48位MAC地址（对于大多数LANs）被烧入到NIC ROM中，但是有时候支持软件设置
 - e.g.: 1A-2F-BB-76-09-AD
 - 十六进制表示法
(每位“数字”代表4 bit)

MAC 地址

每个在LAN中的接口

- 拥有唯一的48位MAC地址
- 拥有一个逻辑上唯一的32位IP地址（就像我们看到的那样）



网络地址和mac地址分离

历史原因：先有各种物理网络（有各自MAC地址），再有IP网络互联（需要定义统一的IP地址）

分离的好处

- a) 更换坏的网卡，MAC地址变化而IP地址不变，不影响使用
- b) 物理网络之上支持IP之外的其他网络层协议，如IPX，Appletalk等

捆绑的问题


- a) IP地址和MAC地址捆绑，意味着只能选择IP协议
- b) 每次上电都要写入IP地址
- c) 另外一个选择：每到来一个帧都要上传到IP层，IP协议实体被中断一次，由它判断是不是需要接收

MAC 地址

- MAC地址分配被IEEE管理
- 厂商购买MAC地址空间的一部分（来确保唯一性）
- 类比：
 - MAC地址：就像社会安全号
 - IP地址：类似于邮政地址
- MAC平面性地址：可移动性
 - 可以将网卡从一个LAN移动到另外一个LAN，不用改变MAC地址
 - 而IP地址不可移动：取决于节点所连接的IP子网

ARP: address resolution protocol

Question: 知道接口的IP地址，如何确定接口的MAC地址？



ARP 表: 每个在LAN上的IP节点（主机，路由器）都有该表格

- 一些LAN节点的IP/MAC 地址映射:

< IP address; MAC address; TTL >

- TTL (Time To Live): 地址映射将会在该时间之后被遗忘（典型20分钟）


ARP协议的运行

例子: A 需要发送IP数据报给B

- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议获知B的MAC地址

A 广播 ARP查询, 包含B的IP地址


- ①
- 目标MAC地址 = FF-FF-FF-FF-FF-FF
 - 所有的LAN节点都会收到该ARP查询



ARP协议的运行

例子: A 需要发送数据报给B


- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议获知B的MAC地址



ARP协议的运行

例子: A 需要发送数据报给B


- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议获知B的MAC地址



路由到其他子网：寻址


演练：通过R将数据报从A发送到B

- 聚焦于寻址 – 在 IP (数据报)层 和 MAC 层（帧）
- 假设：
 - A 知道B的IP地址
 - A 知道送达分组给B的IP地址，第一跳路由器R的IP地址（如何？）
 - A 知道R的MAC地址（如何？）




路由到其他子网：寻址

- A 创建IP数据报，源IP地址A，目标IP地址为B
- A 创建包含A到B IP数据报的链路层帧
 - R的 MAC 地址当作是帧的目标地址（R的MAC地址通过ARP获得）




路由到其他子网：寻址

- 帧从A发送到R
- 帧被R接收，数据报被解封装，向上交给IP协议实体




路由到其他子网：寻址

- R决定数据报的传出接口，将源IP地址为A，目标IP地址为B的数据报交链路层
- R创建链路层的帧包含A-B IP数据报，帧的目标地址：B的MAC地址（通过ARP获得）




路由到其他子网：寻址

- R决定数据报的传出接口，将源IP地址为A，目标IP地址为B的数据报交链路层
- R创建链路层的帧包含A-B IP数据报，帧的目标地址：B的MAC地址
- 传输链路层的帧



路由到其他子网：寻址

- B接收到该帧，解封装IP数据报，目标为B
- B将数据报向上传递到IP协议实体



链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

Ethernet

“占主导地位” 有线LAN技术:


- 第一个被广泛使用的LAN技术
- 更简单，便宜
- 跟上速度竞赛：10 Mbps – 400 Gbps
- 单芯片，多速率（例如：博通Broadcom BCM5761）




Metcalfe's Ethernet sketch

以太网：物理拓扑


- **总线型**：上世纪90年代流行的拓扑
 - 所有的节点在一个碰撞域内 (可能相互碰撞)
- **交换型**：现在占上风
 - 在交换机进行主动链路层2层交换
 - 每个“spoke”运行单独的以太网协议（节点间不会相互发生碰撞）



总线：同轴电缆



集线器：盒中总线



交换机：交换型以太网网络

Ethernet帧结构


发送接口将IP数据报（或者其他网络层协议包）封装在以太网帧中



前导码:

- 用于同步接收方、发送之间的时钟速率
- 7个字节的10101010，后面紧跟着一个字节的10101011

Ethernet帧结构（续）



- **地址:** 6字节目标MAC地址， 6字节源MAC地址
 - 如果适配器收到一个目标地址是本节点MAC地址，或者是广播地址的帧（如：ARP请求报文），它将帧的数据部分向上交给网络层
 - 否则，适配器丢弃该帧
- **类型/长度:** 指示高层的协议
 - 绝大多数为IP，但是可能有其他协议，如： Novell IPX, AppleTalk
 - 在接收方进行多路解复用
- **CRC:** 在接收方进行CRC校验
 - 检测到差错：帧被丢弃


Ethernet: 不可靠，无连接

- **无连接**: 发送方和接收方NIC无需握手
- **不可靠**: 接收方NIC无需发送ACK或者NAK给发送方NIC
 - 只有在原始发送方使用高层rdt（如：TCP）才有可能恢复被丢弃帧中的数据，否则被丢弃帧的数据就会丢失（会被应用看到）
- Ethernet的MAC协议：具有二进制退避的非时隙**CSMA/CD**

802.3 Ethernet 标准: 链路层和物理层

■ 很多以太网标准

- 一致的MAC协议和帧结构
- 不同的速率: 2 Mbps, 10 Mbps, 100 Mbps, 1Gbps, 10 Gbps, 40 Gbps
- 不同的物理层介质: 光纤, 双绞线



链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

Ethernet 交换机

- 交换机是个链路层设备：扮演一个主动角色
 - 存储、转发以太网帧
 - 检查进入帧的目标MAC地址，当该帧是需要从某个网段转发时有选择地从一个或者多个外出链路转发该帧，转发前采用CSMA/CD获得该网段的访问权
- 透明：主机（和路由器）不知道交换机的存在
- 即插即用，自学习
 - 交换机无需配置

交换机: 多个同时的传输


- 主机有到交换机专有、直接连接
- 交换机缓存帧
- 在每个输入链路上使用以太网协议, 所以:
 - 没有碰撞; 全双工
 - 每个链路都本身就是一个碰撞域
- **交换:** A-to-A' 和 B-to-B' 可以同时传输, 没有碰撞



switch with six
interfaces (1,2,3,4,5,6)

交换机: 多个同时的传输

- 主机具有到交换机的专有的，直接连接
- 交换机缓存帧
- 在每个输入链路上使用以太网协议，所以：
 - 没有碰撞；全双工
 - 每个链路都本身就是一个碰撞域
- **交换：** A-to-A' 和 B-to-B' 可以同时传输，没有碰撞
 - 但是A-to-A' 和 C to A'的传输不能够同时进行



switch with six
interfaces (1,2,3,4,5,6)

交换机转发表


Q: 交换机如何知道A'可以通过接口4可达，而B'可以通过接口5可达？

A: 每个交换机有一个**交换表**，每个表项：

- (主机的MAC地址, 到达该主机的接口, 时戳)
- 看起来就像路由器表！


Q: 表项是如何在交换表中被创建与维护的？

- 类似于路由协议？



交换机: 自学习

- 交换机**学习**可以通过哪个交换机端口到达哪些主机
 - 当帧被接收时, 交换机“学习”发送方的位置: 进入LAN的网段, 即交换机端口
 - 在交换表中记录(发送方MAC/位置交换机端口)对



MAC addr	interface	TTL
A	1	60

*Switch table
(initially empty)*


交换机: 帧过滤/转发

当交换机接收到帧时:

1. 记录进入的链路（交换机端口，发送主机的MAC地址）
2. 用目标MAC地址检索交换表
3. **if** 该目标MAC地址在交换表中的表项中能够被发现
 then {
 if 目标MAC地址在进入该帧的网段（交换机端口）
 then 丢弃该帧
 else 向交换表表项指示的接口转发该帧
 }
 else 泛洪 /* 除了帧进入的端口，向所有其他端口转发*/

自学习, 转发: 例子

- 帧的目标, A' , 如位置不知道: 泛洪
- 如目标 A 位置知道
就向一个链路 (端口) 选择性发送




MAC addr	interface	TTL
A	1	60
A'	4	60

交换表
(初始为空)

交换机互联

自学习交换机可以级联到一起：




Q: 从A发送到G – S₁交换机如何知道需要通过S₄和S₃转发目标为G的帧？

■ **A:** 自学习！（工作原理和单个交换机是完全一样的）


自学习多个交换机的例子

假设C发送帧到I，I回应给C



Q: 显示交换机表和数据包在 S_1 , S_2 , S_3 , S_4 中的转发

小型机构网络




交换机 vs. 路由器

都是存储转发设备:

- **路由器**: 网络层设备(检查网络层头部)
- **交换机**: 链路层设备(检查链路层头部)

都有转发表:

- **路由器**: 采用路由选择算法计算路由表, 基于IP地址
- **交换机**: 采用泛洪、自学习来获得转发表, 基于MAC地址



链路层，LAN：提纲


- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

Virtual LANs (VLANs): 动机

Q: 当LAN的规模不断增大，用户不断变换其上网地点会发生什么？




一个广播域:

- **扩展性:** 所有的2层广播流量(ARP, DHCP, 目标MAC未知的帧)必须穿越全部LAN
- 效率, 安全性, 隐私性问题

Virtual LANs (VLANs): 动机

Q: 当LAN的规模扩大，用户变换接入网络的连接点时，什么会发生？



单个广播域:

- **扩展性:** 所有2层的广播流量（ARP, DHCP, 未知的MAC）必须穿过整个LAN
- 效率，安全，隐私性问题

管理问题：


- CS用户将其办公室移动到EE-物理上接入EE交换机，但仍然希望逻辑地通过CS交换机接入

基于端口的 VLANs


Virtual Local Area Network (VLAN)

在单个物理LAN基础设施上，支持VLAN能力的交换机可以被配置成定义多个虚拟VLAN

基于端口的VLAN: 交换机端口分组（通过交换机管理软件），以便于单个物理交换机.....




.. 作为多个虚拟交换机运行




基于端口的 VLANs

- **流量隔离**：进出1-8端口的帧可以只到达端口1-8
 - 不仅可以基于端口的定义VLAN
 - 也可以基于接入节点的MAC地址定义VLAN
- **动态成员**：可以在VLAN中动态分配端口
- **在VLAN之间转发**：通过路由进行（就像使用单独交换机一样）
 - 实际上设备商供应：集成了交换机和路由器的设备




跨越多个交换机的VLAN



干线端口: 在多个交换机之间共享所定义的VLAN

- 通过干线端口，干线转发 交换机之间的帧
- 在干线上，交换机间转发的帧不可能是普通802.1的帧（必须携带VLAN ID信息）
- 802.1q协议规范了：在干线端口转发的帧，如何增加和删除额外的头部字段

802.1Q VLAN 帧格式



链路层，LAN：提纲


- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

多协议标签交换（MPLS: Multiprotocol label switching）


- **目标：** 采用固定长度的标签，在具有MPLS能力的路由器间进行快速的IP转发 (替代目标IP地址的最长前缀匹配)
 - 采用固定长度标签标识进行更加快速的查找
 - 借鉴了虚电路方法的思路
 - 但是IP数据报仍然保留IP地址！



具有MPLS能力的路由器


- a.k.a. 标签交换路由器
- 仅基于标签值将数据报转发到输出链路（不再检查数据报的IP地址）
 - MPLS转发表和IP转发表不同
- **弹性：** MPLS转发确定可能与IP不同
 - 采用目标和源地址将到同样目标的流区分处理（流量工程）
 - 如果链路失效可以机型快速重新路由：预先计算的备份路径

MPLS versus IP 路径



- IP 路由：到达目标的路径仅由目标地址决定


MPLS versus IP 路径




- **IP 路由**: 到达目标的路径仅由目标地址决定
- **MPLS 路由**: 到达目标的路径可以基于源和目标地址
 - 通用转发的风格 (MPLS 10年前)
 - 快速重新路由: 当发生链路失效时采用预先计算的备份路由

MPLS 信令

- 修改OSPF, IS-IS链路状态泛洪协议让它们用于携带MPLS路由所需要信息：
 - e.g., 链路带宽, “预留” 链路带宽的量
- MPLS入口路由器采用RSVP-TE信令协议来在下游路由器上设置MPLS转发



MPLS 转发表



链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

数据中心网络

1w到10w台主机，紧耦合，物理位置相近：

- 电子商务 (e.g. Amazon)
- 内容服务器 (e.g., YouTube, Akamai, Apple, Microsoft)
- 搜索引擎，数据挖掘 (e.g., Google)


挑战：

- 多种应用，每个服务大量的客户
- 可靠性
- 管理/负载均衡，避免处理，网络里，数据瓶颈



Inside a 40-ft Microsoft container, Chicago data center

数据中心网络: 网元



边界路由器

- 连接到数据中心外部

Tier-1 交换机

- 下面连接到大约 ~16 T-2交换机

Tier-2 交换机

- 下面连接到大约 ~16 TORs

机顶 (TOR) 交换机


- 每个机柜一个
- 40-100Gbps以太网到刀片

服务器阵列

- 20- 40 服务器刀片: 主机

数据中心网络：网元


Facebook F16 数据中心网络拓扑：



<https://engineering.fb.com/data-center-engineering/f16-minipack/> (posted 3/2019)


数据中心网络：多路径

- 交换机，阵列之间的丰富互联：
 - 增加阵列之间吞吐（可能有多路由路径）
 - 通过冗余增加可靠性



在阵列1和11之间的2个突出显示的不交叉路径

数据中心网络：应用层路由



负载均衡：应用层路由

- 接收外部的客户端请求
- 导流工作载荷到数据中心
- 向外部的客户端返回结果
- （对客户端隐藏了数据中心的内部）

数据中心网络：协议创新

■ 链路层：

- RoCE: remote DMA (RDMA) over Converged Ethernet

■ 传输层：

- ECN (explicit congestion notification) 被用于传输层的拥塞控制 (DCTCP, DCQCN)
- 逐跳（反向压力）拥塞控制实验

■ 路由，管理：

- 在机构的数据中心内部和之间SDN 被广泛使用
- 将相关服务和数据尽可能放置近一些，（例如：在一个阵列或者相近的阵列中）最小化2级，1级的通信

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

综合：web页面请求的历程

- 我们自上而下的协议栈旅行结束了！
 - 应用层，传输层，网络层和链路层
- 把它们放到一起按照时间线展开介绍各协议实体动作！
 - **目标：** 识别、复习、理解看似简单的场景中所涉及的协议（所有层次）： 请求www页面
 - **场景：** 学生将笔记本连接到校园网，请求和接收www.google.com的网页

历程：场景




场景:

- 到达的移动客户端连接到了网络 ...
- 请求web网页: `www.google.com`


看起来
很简单!

历程：连接到互联网



- 连接的笔记本需要一个IP地址，第一跳路由器的IP地址，DNS的地址: 采用 **DHCP**
- ❖ DHCP 请求被封装在UDP中，封装在IP数据报中, 封装在 802.3 以太网帧中
- ❖ 以太网的帧在LAN上广播 (dest: FFFFFFFFFFFFFFFF), 被运行中的**DHCP**服务器接收到
- ❖ 以太网帧中封装IP分组，封装UDP，UDP数据报封装DHCP请求报文


历程：连接到互联网



- DHCP 服务器生成 **DHCP ACK** 包括客户端 IP 地址，第一跳路由器 IP 地址和 DNS 名字服务器地址
- 在 DHCP 服务器进行封装，帧通过 LAN 转发（交换机学习），在客户端进行解封
- DHCP 客户端接收 DHCP ACK 响应报文


客户端现在拥有 IP 地址，
知道 DNS 服务器的名字和地址，以及第一跳路由器的 IP 地址

历程... ARP (在DNS和HTTP之前)



- DNS 在发送HTTP请求报文之前，需要 www.google.com 的IP地址
- DNS查询报文被创建，封装在UDP数据报中，封装在IP数据报中，封装在以太网帧中，将之发送给路由器，需要路由器接口的MAC地址：ARP
- ARP查询广播发送，路由器接收，然后路由器给出ARP响应报文，告诉请求方路由器接口的MAC地址，
- 客户端现在知道第一跳路由器的MAC地址，所以它可以发送包含有DNS查询的帧了


历程... 使用DNS



- 包含有DNS查询的IP数据报通过LAN交换机从客户端转发到第一跳路由器
- IP数据报从校园网转发到Comcast网络，路由（表项被RIP,OSPF,IS-IS和/或BGP路由协议）到DNS服务器


- IP数据报（包含DNS请求报文）解封装给DNS
- DNS用www.google.com的IP地址来回复给客户端

历程...承载有HTTP的TCP连接



- 为了发送HTTP请求，客户端首先打开到web服务器的TCP socket
- TCP **SYN** 段 (TCP 3次握手的第一步) 通过域间路由到web服务器
- Web服务器用TCP **SYNACK** (TCP 连接的第2步) 响应客户端
- TCP 连接建立起来!

历程... HTTP 请求/响应



- HTTP 请求发送给TCP socket
- 包含有HTTP请求的IP数据报路由到www.google.com
- web 服务器用HTTP 响应报文（包含有web网页）回应
- 包含有HTTP 响应报文的IP数据报路由回客户端

第6章：总结

- 数据链路层服务背后的原理：
 - 检错，纠错
 - 共享广播型信道：多路访问
 - 链路层编址
- 各种链路层技术的实例和实现
 - 以太网
 - 交换式局域网，VLANs
 - 虚拟化链路层的网络：MPLS
- 综合：web请求的历程

第6章：让我们休息一下

- 自顶向下讲解**全部**网络协议栈旅程结束了（除了物理层）
- 坚实理解了网络原理和实践！
- ……可以在这里停下…。但是有**更加**有趣的主题！
 - 无线网络
 - 安全

第6章 附加幻灯片

纯 ALOHA 效率

$$P(\text{给定节点成功}) = P(\text{该节点传输}) \cdot$$

$$P(\text{没有其他节点在 } [t_0-1, t_0] \text{ 传输}) \cdot$$

$$P(\text{没有其他节点在 } [t_0, t_0+1] \text{ 传输}) \cdot$$

$$= p \cdot (1-p)^{N-1} \cdot (1-p)^{N-1}$$

$$= p \cdot (1-p)^{2(N-1)}$$

... 选择最优值 p , 让 $N \rightarrow \infty$

$$= 1/(2e) = .18$$

甚至比时隙Aloha要来得差!